

TRABAJO FIN DE GRADO

DEMANDA ELÉCTRICA PENINSULAR Y AUTOCONSUMO: MODELIZACIÓN ARIMA Y ANÁLISIS DEL REGRESOR RADIACIÓN

TRABAJO FIN DE GRADO PARA
LA OBTENCIÓN DEL TÍTULO DE
GRADUADO EN INGENIERÍA EN
TECNOLOGÍAS INDUSTRIALES

FEBRERO 2026

Jesús Zárate Renet

DIRECTOR DEL TRABAJO FIN DE GRADO:
Jesús Juan Ruiz

“La inteligencia, desprovista de disciplina, resulta estéril”

- Rafael Escobar Orellana

AGRADECIMIENTOS

Este trabajo va dedicado a todas aquellas personas que pusieron en mí la confianza y las condiciones de contorno para poder llegar hasta este punto, acabar la carrera.

Gracias por tanto a Cristo Rey, a mi tutor Jesús Juan, a mis padres, a Rafael Escobar, a Fray Rafael Pascual y de forma muy especial a mi tío y padrino Juan y a mi tía Vitori.

RESUMEN EJECUTIVO

La energía eléctrica se ha convertido en uno de los pilares fundamentales de la sociedad actual, actividades cotidianas, funcionamientos de hospitales, movilidad eléctrica, la creciente digitalización de la economía, industria, etc. dependen directamente de un suministro eléctrico continuo y fiable. Esta dependencia quedó manifiesta en el apagón vivido en abril del año 2025, evidenciando la importancia de mantener el equilibrio entre generación y consumo en un sistema eléctrico cada vez más complejo.

En un contexto marcado por la transición energética, la electrificación de la demanda y una, cada vez mayor, integración de las energías renovables se ha convertido en una necesidad técnica y estratégica. A diferencia de otras formas de energía, la electricidad no puede almacenarse de forma sencilla a gran escala, lo que obliga a que la demanda sea atendida de forma prácticamente instantánea por la oferta disponible. De este equilibrio se encarga diariamente el operador del sistema, Red Eléctrica Española (REE).

La creciente penetración de las energía renovables y en particular del autoconsumo fotovoltaico, ha introducido en España una nuevas dinámicas en los patrones tradicionales de consumo eléctrico. Esto ha provocado que una parte creciente de la energía consumida no pase por los contadores de la red, dificultando la estimación y predicción de la demanda real.

En este escenario, es fundamental el desarrollo de modelos capaces de incorporar de forma adecuada los efectos de variables explicativas como las festividades, temperatura o la radiación solar, con el fin, precisamente, de facilitar la operación eficiente del sistema.

Es por tanto, el objetivo del presente Trabajo de Fin de Grado el constituir un modelo estadístico de la demanda eléctrica horaria en el sistema peninsular español, basándose en series temporales, así como el análisis estadístico del autoconsumo fotovoltaico a través del regresor radiación.

Para ello, se han creado modelos ARIMA para cada una de las 24 horas, incorporando progresivamente las diferentes variables explicativas ya mencionadas y dando lugar a modelos del tipo Reg-ARIMA.

En el análisis del regresor radiación, se puede concluir que en términos generales, se consiguen mejoras para las horas centrales del día, reduciendo el error típico de los residuos hasta el 3 %, además se aprecia un incremento en su magnitud de forma consistente a partir del 2021, presentando una clara estacionalidad del mismo al estimar los coeficientes del modelo por trimestres desde el 1 de enero de 2021 hasta el 30 de mayo de 2025.

Como parte final del Trabajo, se ha estimado el autoconsumo fotovoltaico como efecto atribuible a la radiación solar basándose en la información de demanda observada para el periodo 2021-2025 y los coeficientes por horas y trimestre.

A partir de estas estimaciones, y coherente con las informaciones y noticias disponibles sobre la potencia instalada, se han obtenido cifras como que en mayo de 2025 el autoconsumo fotovoltaico llegó a representar un 10 % de la demanda, o como que en el año 2021 se estima que el autoconsumo llegó a generar en torno a 5300 GWh , mientras que en 2024 esta cifra alcanzaba ya los 13000 GWh, representando un incremento del 145 % acumulado en solo 2 años.

Se puede concluir, gracias a este Trabajo de Fin de Grado, que es posible una mayor comprensión de las nuevas dinámicas del sistema eléctrico y que el uso de energías renovables como puede ser el autoconsumo fotovoltaico es ya una realidad en España la cual necesita ser estudiada en

mayor profundidad, obtener datos serios y oficiales sobre la potencia instalada en los hogares españoles así como la generación eléctrica a través de la misma, ya que el orden de magnitud que a día de hoy ya maneja el autoconsumo es notable y afecta de manera sobresaliente a la predicción para el correcto equilibrio entre la demanda y el consumo en España.

ÍNDICE

AGRADECIMIENTOS	III
ÍNDICE DE TABLAS	XII
ÍNDICE DE FIGURAS	XV
ÍNDICE DE CÓDIGOS	XVI
1. INTRODUCCIÓN	1
1.1. Qué es la electricidad y su papel en la vida moderna	1
1.2. El futuro de la electricidad	1
1.3. Estructura del sistema eléctrico español	1
1.3.1. Generación	2
1.3.2. Transporte	3
1.3.3. Distribución	3
1.3.4. Comercialización	3
1.4. Demanda eléctrica	4
1.4.1. Definición y relevancia	4
1.4.2. Factores que influyen en la demanda	4
2. OBJETIVOS	5
3. METODOLOGÍA	6
3.1. Base de datos	6
3.2. Modelo estadístico: Series Temporales	6
3.3. Modelo ARIMA	8
3.3.1. Estacionalidad	9
3.3.2. Preparación del modelo	12
3.3.3. Funciones de autocorrelación	16
3.3.4. Parámetros del modelo	17

3.3.5.	Modelos para las 24 horas del día	20
3.3.6.	Fórmula del modelo	23
4.	MODELIZACIÓN Y ESTIMACIÓN	24
4.1.	Modelo Reg- ARIMA con festivos	25
4.2.	Modelo Reg-ARIMA con temperatura	30
4.3.	Modelo Reg-ARIMA con radiación	35
4.3.1.	Diagnosis y validación del modelo	40
4.3.2.	Regresor Radiación y coeficientes	41
4.3.3.	Estimación del autoconsumo con la radiación	45
4.3.4.	Interpretación del efecto de la radiación y construcción energética del au- toconsumo	47
5.	CONCLUSIONES Y POSIBLES LÍNEAS FUTURAS	52
5.1.	Conclusiones	52
5.2.	Limitaciones y líneas futuras	52
6.	PLANIFICACIÓN Y PRESUPUESTO	54
6.1.	Plantilla de EDP	54
6.2.	Presupuesto	55
6.3.	Diagrama de Gantt	56
7.	CÓDIGO	58
7.1.	Lectura de datos y primeros pasos	58
7.2.	Cambios de hora	59
7.3.	Creación del modelo	61
7.4.	Regresor festivos	63
7.5.	Regresor temperatura	64
7.6.	Regresor radiación	65
7.6.1.	Modelización horaria con regresor de radiación y efecto trimestral	66
7.6.2.	Autoconsumo horario a partir de los coeficientes estimados	67

7.7. Estimación del autoconsumo energético	69
ANEXOS	71
H. Bibliografía	71
I. Algoritmo para la creación de modelos ARIMA	73
I.1. Pasos para ARIMA(p,d,q)	73
I.2. Selección del modelo	74

ÍNDICE DE TABLAS

3.1. Comparación de modelos ARIMA para la hora 10	17
3.2. Estimación de parámetros del modelo ARIMA para la hora 10	18
3.3. Parámetros estimados y errores del modelo ARIMA para cada hora del día	20
4.1. Errores de predicción del modelo ARIMA por hora del día: MAPE y varianza residual	26
4.2. Coeficientes estimados por trimestre para la hora 16	42
6.1. Estimación del presupuesto asociado a la realización del Trabajo de Fin de Grado	55

ÍNDICE DE FIGURAS

1.1. Estructura de generación de energía eléctrica en España (2024). Fuente: Red Eléctrica de España [5].	2
1.2. Demanda de electricidad (TWh) y evolución del PIB en España. Fuente: AleaSoft con datos de REE e INE (1995–2020) [9]	4
2.1. Evolución anual de la potencia de autoconsumo instalada en España, diferenciando entre proyectos industriales y residenciales. Fuente: APPA Renovables, reproducido por EDP Energía [10].	5
3.1. Evolución de la demanda eléctrica en España a las 12 horas a lo largo de los años	8
3.2. Demanda eléctrica horaria para un día representativo en cada estación del año.	9
3.3. Evolución de la demanda eléctrica durante los meses de febrero de 2019 hasta finales de abril de 2019	10
3.4. Evolución de la demanda eléctrica en España durante una semana representativa.	10
3.5. Valores atípicos y errores en la demanda eléctrica a las 2:00 h	12
3.6. Valores atípicos y errores en la demanda eléctrica a las 3:00 h	12
3.7. Demanda de la hora que se va a tomar para el cálculo del modelo	14
3.8. Transformación logarítmica de la demanda eléctrica a las 10:00	14
3.9. Primera diferencia de la demanda eléctrica (en logaritmos) a las 10:00	15
3.10. Funciones de autocorrelación parcial (PACF) y autocorrelación simple (ACF) de la serie diferenciada	16
3.11. Funciones de autocorrelación parcial (PACF) y autocorrelación simple (ACF) de la serie diferenciada	16
3.12. Análisis de residuos del modelo : serie temporal de residuos, función de autocorrelación (ACF) e histograma con ajuste normal	18
3.13. Evolución horaria de los parámetros del modelo ARIMA para las 24 horas del día	21
3.14. Evolución horaria de los errores del modelo ARIMA para las 24 horas del día	21
4.1. Estructura de las variables indicadoras de festivos nacionales y regionales utilizadas como regresores en el modelo	26
4.2. Comparación del MAPE horario del modelo ARIMA con y sin incorporación de festivos	27
4.3. Evolución horaria del error medio del modelo ARIMA con incorporación de festivos	27
4.4. Comparación de la demanda eléctrica horaria entre días festivos y no festivos	28
4.5. Resultados del modelo ARIMA con regresores festivos para las 2 de la mañana	28

4.6. Resultados del modelo ARIMA con regresores para las 6 de la mañana	29
4.7. Relación entre la temperatura y la demanda eléctrica en la hora 10	30
4.8. Relación entre temperatura y demanda eléctrica en la hora 10 diferenciando días laborables, sábados y domingos	31
4.9. Evolución del MAPE por hora del día para los distintos modelos considerados . .	32
4.10. Evolución del parámetro σ por hora del día para los distintos modelos considerados	32
4.11. Resultados del modelo ARIMA con regresores festivos y térmicos para la hora 2 .	33
4.12. Resultados del modelo ARIMA con regresores festivos y térmicos para la hora 14	33
4.13. Relación entre radiación solar y demanda eléctrica en la hora 10, diferenciando días laborables, sábados y domingos	35
4.14. Evolución horaria de los coeficientes asociados a z_{rad} y z_{rad}^2	36
4.15. Resultados del modelo ARIMA con regresores festivos, térmicos y de radiación para la hora 2	37
4.16. Resultados del modelo ARIMA con regresores festivos, térmicos y de radiación para la hora 16	37
4.17. Evolución del MAPE por hora del día para los distintos modelos considerados . .	38
4.18. Evolución del parámetro σ por hora del día para los distintos modelos considerados	38
4.19. Diagnóstico de residuos del modelo ARIMA(0,1,2)(0,1,1)[7]: serie temporal de residuos, función de autocorrelación y distribución	40
4.20. Matriz de regresores por trimestres. Visualización del cambio de la radiación solar normalizada entre trimestres, utilizada como variable explicativa en el modelo. .	42
4.21. Evolución trimestral del coeficiente asociado a la radiación solar para las horas 16,11 y 3	43
4.22. Coeficientes no significativos para la hora 3 en todos los trimestres	44
4.23. Matriz Autoconsumo $_{h,q,d}$ de coeficientes estimados por hora. Cada columna re- presenta una hora del día y cada fila un día, mostrando la variación del efecto de la radiación solar a lo largo del tiempo.	46
4.24. Autoconsumo estimado horario en el sistema eléctrico peninsular (2021–2025). .	48
4.25. Autoconsumo mensual estimado en el sistema eléctrico peninsular (2021–2025). .	48
4.26. Evolución del autoconsumo eléctrico en España y comparación con los objetivos marcados por la Agenda 2030. Fuente: Newtral, reproducido de [19].	49
4.27. Evolución y crecimiento interanual de la potencia de autoconsumo fotovoltaico instalada en España. Fuente: C de Comunicación, reproducido de [20].	50
4.28. Autoconsumo trimestral estimado en el sistema eléctrico peninsular (2021–2025).	50

4.29. Porcentaje de autoconsumo mensual respecto al total de la demanda eléctrica del sistema peninsular (2021–2025).	51
6.1. Estructura de Descomposición del Proyecto (EDP) del trabajo.	54
6.2. Diagrama de Gantt del Trabajo de Fin de Grado (febrero 2025 – enero 2026). . .	57
I.1. Diagrama de decisión para la comprobación de estacionariedad y preprocesado de series temporales previo al modelado ARIMA.	73
I.2. Comportamiento teórico de las funciones ACF y PACF en procesos AR, MA y ARMA.	74

ÍNDICE DE CÓDIGOS

7.1. Carga de librerías y primeras comprobaciones.	58
7.2. Corrección de las series horarias de demanda eléctrica asociadas a los cambios de hora oficiales (horario de verano e invierno).	59
7.3. Corrección de las series horarias de demanda eléctrica asociadas a los cambios de hora oficiales (horario de verano e invierno).	60
7.4. Transformación logarítmica y diferenciación de la serie horaria de demanda eléctrica a las 10:00.	61
7.5. Funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) de la serie diferenciada de demanda eléctrica a las 10:00.	61
7.6. Corrección de la estacionalidad semanal y análisis ACF y PACF de la serie transformada.	61
7.7. Estimación y comparación de distintas especificaciones ARIMA estacionales para la demanda eléctrica a las 10:00.	62
7.8. Creación de festividades e inclusión de las variables festivas como regresores en modelos ARIMA de demanda eléctrica.	63
7.9. Inclusión de la temperatura y variables festivas como regresores en modelos ARIMA de demanda eléctrica.	64
7.10. Inclusión de las variables festivas, temperatura y radiación como regresores en modelos ARIMA de demanda eléctrica.	65
7.11. Construcción del regresor de radiación solar con efectos trimestrales e inclusión en modelos ARIMA horarios de demanda eléctrica.	66
7.12. Construcción de la matriz de autoconsumo horario mediante la combinación de coeficientes trimestrales estimados y radiación solar diaria estandarizada.	67
7.13. Pasos previos necesarios para la ejecución del código.	68
7.14. Cálculo del autoconsumo energético a partir de la demanda observada y la matriz de efectos relativos estimados.	69
7.15. Cálculo del autoconsumo energético a partir de la demanda observada y la matriz de efectos relativos estimados.	69
7.16. Agregación del autoconsumo energético estimado a escala mensual y representación gráfica en GWh.	69
7.17. Agregación trimestral del autoconsumo energético estimado y representación mediante gráfico de barras.	70
7.18. Porcentaje mensual de autoconsumo estimado respecto a la demanda eléctrica total.	70

1. INTRODUCCIÓN

1.1. Qué es la electricidad y su papel en la vida moderna

La electricidad se define como el tipo de energía resultante del movimiento de partículas cargadas (por lo general electrones), a través de un conductor (por lo general hilos de cobre). Una de las bondades de la electricidad es que tiene múltiples aplicaciones y es relativamente sencilla transformarla en otra forma de energía (térmica, mecánica, etc.) [1].

En la actualidad la electricidad es un pilar fundamental en la sociedad para el correcto funcionamiento de todo tipo de actividades desde las tareas domésticas (iluminación, refrigeración, climatización) hasta la industria (realización de procesos industriales, puesta en marcha de maquinaria, etc.), siendo cada vez más importante en sectores como el transporte o las telecomunicaciones.

1.2. El futuro de la electricidad

A diferencia de otras formas de energía, la perspectiva a futuro del consumo de la electricidad es claramente a más, esto se debe a varios factores como pueden ser:

- Crecimiento de la demografía mundial.
- Electrificación del sector del transporte.
- Digitalización y uso de las tecnologías.

Según la Agencia Internacional de la Energía [2] se preveen un crecimiento en el consumo mundial del 3,3 % para finales de 2025 y de un 3,7 % para 2026.

Por tanto es notable que este aumento en la demanda tiene que ser correspondido con una oferta energética sólida para poder evitar apagones como el que se produjo en gran parte de la península ibérica durante el mes de abril de 2025 [3].

1.3. Estructura del sistema eléctrico español

La forma de organización del sistema eléctrico español, desde la generación hasta el consumo final, es relativamente diferente a la de otras “*commodities*”.

Se puede considerar que está organizado en cuatro grandes bloques funcionales:

1. Generación
2. Transporte
3. Distribución
4. Comercialización

Esta estructura funcional del sistema eléctrico español, desde la generación hasta la comercialización, se encuentra claramente definida y regulada por el operador del sistema y los organismos supervisores del sector [4].

1.3.1. Generación

Es la fase inicial del proceso eléctrico, en la que se transforma una fuente de energía primaria en energía eléctrica, según el tipo de esta fuente primaria podemos clasificarlas en:

- Fuentes renovables: eólicas, solar fotovoltaica, solar térmica, hidráulica, biomasa o geotérmica.
- Fuentes no renovables: nuclear, carbón (prácticamente desaparecida) y ciclos combinados (gas natural).

Se podría hacer incluso una mayor división entre fuentes regulables como la nuclear o la hidráulica y no regulables como pueden ser la solar y la eólica.




Figura 1.1: Estructura de generación de energía eléctrica en España (2024). Fuente: Red Eléctrica de España [5].

Además sobre la generación podemos decir que se lleva a cabo por empresas privadas, mixtas o públicas, conocidas como “operadores de generación” las cuales tienen derechos sobre infraestructuras concretas como son las presas, los embalses, etc. lo que la empresa posee en propiedad es la maquinaria para la obtención de la energía primaria.

Hay que remarcar que estas concesiones vienen de la mano de ciertas regulaciones y normativas medioambientales, de seguridad y de mercado además de que sus operaciones deben estar coordinadas e integradas en la planificación del sistema eléctrico según las indicaciones del operador del sistema. Las ganancias de estas empresas vienen de su participación en el mercado mayorista eléctrico así como contratos bilaterales con grandes consumidores y subvenciones.

1.3.2. Transporte

Consiste básicamente en llevar la electricidad a alta tensión (nótese que las pérdidas por efecto Joule la intensidad crece cuadráticamente y que por tanto si queremos mantener la potencia entonces se tendrá que aumentar el voltaje).

Pérdidas por efecto Joule: $P = I^2 R$

Ley de Ohm: $V = IR$

P = potencia disipada [W] I = corriente [A] R = resistencia [Ω] V = tensión [V]

El voltaje es elevado hasta los 220-440 kV, permitiendo llevar de forma óptima la electricidad hasta los puntos de distribución.

En España solo hay un operador de transporte que es Red Eléctrica de España (REE), gestiona y supervisa todo el sistema en tiempo real, intentando que este se mantenga equilibrado. Es importante entender que REE ni compra ni vende energía, realizar un papel exclusivo de gestor técnico y de operador de red[6].

Como dato, para entender la extensión e importancia de la Red Eléctrica de España, comentar que cuenta con mas de 455000 kilómetros de alta tensión y más de 700 subestaciones y más de 225 transformadores [7] (sin incluir los grupos de generación y los elementos de conexión de dichos grupos a la red no están incluidos).

1.3.3. Distribución

Una vez que la electricidad ha sido transportada esta llega a los centros urbanos o industriales, a partir de ahí la electricidad se lleva hasta el consumidor final, es la última etapa antes de ser consumida. Esto se hace a través de distribuidoras locales (las cuales no se pueden elegir, solo es posible la elección de las comercializadoras).

1.3.4. Comercialización

Es la venta de la energía eléctrica a los consumidores, las comercializadoras tienen las siguientes funciones:

- Comprar electricidad en el mercado mayorista
- Ofrecerla a los consumidores con diferentes tarifas, condiciones contractuales,etc.
- Facturación y atención al cliente
- Pueden realizar servicios de de asesoría, instalación de autoconsumo,etc.

Su función es unicamente la gestión de la relación comercial con el cliente, no poseen redes físicas ni de transporte ni de distribución[8].

1.4. Demanda eléctrica

1.4.1. Definición y relevancia

Se define demanda eléctrica como la cantidad de electricidad que los consumidores necesitan en un momento determinado. Es fundamental no confundirla con la producción eléctrica ya que esta correspondería con la oferta.

Se mide en potencia (KW, MW, GW) o también en energía (KWh, MWh, GWh), representando la electricidad consumida durante un periodo de tiempo. Además, si la generación de energía es superior a la demandada puede haber sobrecargas o daños en la red, de ahí la importancia de prever con antelación la energía que se va a ser demandada a cada día y cada hora, tarea que hace el operador de red, Red Eléctrica Española.

1.4.2. Factores que influyen en la demanda

Son los siguientes:

- Calendario: fines de semana, festivos nacionales, regionales y locales, cambios de hora, etc. provocan una disminución de la demanda.
- Días laborables: el calendario laboral tiene una fuerte influencia en los patrones de consumo eléctrico, ya que en los días laborables se aprecia mayor demanda mientras que los fines de semana estas es menor.
- Clima y temperatura: en especial los cambios de tiempo y temperatura es uno de los factores más notables en la demanda, con el uso de sistemas de calefacción y de refrigeración.
- Factores varios: existen otros factores que afectan notablemente a la demanda, como son el autoconsumo (a través de placas fotovoltaicas) o los ciclos económicos (durante las recesiones la demanda se ve afectado negativamente).




Figura 1.2: Demanda de electricidad (TWh) y evolución del PIB en España. Fuente: AleaSoft con datos de REE e INE (1995–2020) [9]

2. OBJETIVOS

Los objetivos de este Trabajo de Fin de Grado son analizar y explicar los factores que afectan a la demanda eléctrica. De forma concreta se analizará cómo afecta el autoconsumo y el uso que hacen de él los españoles que habitan en la península ibérica en los diferentes momentos del día y durante las diferentes temporadas del año.

Esta necesidad surge como respuesta a esta creciente tendencia de los últimos años a usar instalaciones fotovoltaicas residenciales e industriales y que complican y modifican de forma notable los patrones tradicionales de consumo, introduciendo nuevas dinámicas que están afectando a la demanda eléctrica y provocando un desajuste entre los valores que se predicen y los que posteriormente se demandan.

En términos técnicos, el objetivo del trabajo es analizar cómo la incorporación del autoconsumo eléctrico influye en la dinámica de la demanda eléctrica peninsular. Para ello, se emplean modelos ARIMA (a través del uso de series temporales), ampliados mediante la inclusión de variables explicativas (radiación peninsular) que permitan cuantificar el impacto del autoconsumo sobre la evolución de la demanda.

De manera concreta y definitiva este Trabajo de Fin de Grado aspira a:

- Construir y justificar un modelo de la demanda eléctrica usando datos recientes.
- Identificar y analizar el impacto del autoconsumo sobre dicha demanda.
- Explicar con claridad cómo el autoconsumo puede estar transformando el patrón de consumo energético en la península ibérica, destacando su relación con la transición energética y la fotovoltaica.




Figura 2.1: Evolución anual de la potencia de autoconsumo instalada en España, diferenciando entre proyectos industriales y residenciales. Fuente: APPA Renovables, reproducido por EDP Energía [10].

3. METODOLOGÍA

Para desarrollar este trabajo se han requerido dos elementos fundamentales que permiten estructurar el análisis de la manera más rigurosa posible:

1. Base de datos sólida y fiable la cual se limpia para poder trabajar con ella posteriormente.
2. El uso de un modelo estadístico a partir del cual poder, con la base de datos, hallar conclusiones.

3.1. Base de datos

Podemos concretar que los datos son proporcionados por la Red Eléctrica Española y consta de la siguiente información:

- Fechas desde el día 1 de enero de 2011 hasta el 30 de mayo de 2025, con los MW demandados en cada una de las 24 horas de cada día.
- Las temperaturas mínimas y máximas peninsulares así como la radiación media en la superficie peninsular.
- Regresores asociados a los días festivos, pandemia de Covid-19 y días de agosto con mayor cantidad de gente en periodo vacacional.

3.2. Modelo estadístico: Series Temporales

A la hora de estudiar la demanda eléctrica y el impacto del autoconsumo sobre la misma existen múltiples enfoques estadísticos (y econométricos) que se pueden usar. Entre estas metodologías podemos encontrar las siguientes:

- Modelos de machine learning
- Redes neuronales artificiales
- Modelos econométricos como VAR (Vector Autoregressive Model)
- Clustering (para clasificar perfiles de consumo o tipos de consumidores)

Sin embargo a pesar de todas estas variedades, se opta por usar modelos de series temporales por las siguientes razones [11]:

- La demanda eléctrica es un fenómeno temporal y estacional , lo cual es precisamente el tipo de patrón que los modelos de series temporales están diseñados para capturar.
- Se adaptan muy bien al objetivo de entender la dinámica temporal (no tanto el segmentar o el clasificar como se harían en otros modos).
- Se adaptan positivamente a los datos reales del sistema eléctrico español (fuertes estacionalidades, tendencias , variaciones por clima o actividades como el autoconsumo,etc.).

- Este concepto de series temporales está alineados con los estudios cursados en el Grado de Ingeniería en Tecnologías Industriales, además es frecuente en la literatura del sector(en muchos informes de REE se emplean series temporales).

Además de usar series temporales, se ha decidido usar el software de R en vez de otros entornos como Matlab o Python debido que R es más familiar y se ha usado más durante el proceso formativo del alumnos así como la especificidad de R para modelos estadísticos como las series temporales mediante paquetes específicos como es “forecast” y ecosistemas bastante desarrollados y documentados.

3.3. Modelo ARIMA

A través de la base de datos se obtienen la evolución de la demanda eléctrica a lo largo de los años para cada una de las 24 horas. Se muestra a continuación la evolución para las 12 del mediodía:




Figura 3.1: Evolución de la demanda eléctrica en España a las 12 horas a lo largo de los años

Se puede ver que a raíz de la pandemia de la Covid-19 [12] hubo un descenso importante en la demanda en particular en los meses de confinamiento, esto se debió principalmente a la reducción de la actividad industrial.

Además la demanda eléctrica a partir de ese momento no ha vuelto a comportarse como en los años anteriores, quizás por factores como el teletrabajo, el autoconsumo, etc.

Desde un punto de vista estadístico se puede observar que hay una gran variabilidad dependiendo del momento del año en el que se desee analizar la demanda a dicha hora, además la media de la serie no permanece constante, esto provoca que la serie no sea estacionaria y que por tanto haya que realizar posteriores cambios para poder trabajar con ella.

Además de estas características, la serie presenta patrones periódicos claramente identificables, cuya naturaleza y tratamiento se analizan en el apartado siguiente

3.3.1. Estacionalidad

Usando diferentes herramientas del software como el selector de rangos temporales se puede analizar con mayor detenimiento el componente estacional de la demanda. A continuación se va a visualizar la demanda desde diferentes ópticas para poder ver de manera adecuada los diferentes patrones que se repiten.




Figura 3.2: Demanda eléctrica horaria para un día representativo en cada estación del año.

Como se observa en la Figura 3.2, la demanda eléctrica presenta perfiles horarios claramente diferenciados según la estación del año en la que se encuentre. Estas diferencias están directamente relacionadas con factores como el clima, hábitos de consumo y patrones de actividad diaria, los cuales varían de manera notable a lo largo del año.

En los meses de invierno se puede ver que la demanda tiende a incrementarse durante las primeras horas de la mañana y al final del día, debido principalmente al uso de sistemas de calefacción, iluminación artificial y a la coincidencia con los horarios laborales y domésticos.

Sin embargo durante el verano se aprecia un aumento más pronunciado en las horas centrales del día, asociado al uso intensivo de sistemas de climatización y refrigeración, especialmente en las horas de mayor radiación solar, ya que suelen ser aquellas en las que hace más calor.

Las estaciones intermedias (primavera y otoño) muestran perfiles más suave, con menores picos de demanda y una menor amplitud entre los valores máximos y mínimos diarios. Este comportamiento refleja una menor necesidad de climatización, y que por tanto el consumo sea más estable.

Desde el punto de vista del modelado estadístico, esta estacionalidad horaria resulta bastante relevante, ya que justifica el análisis de la demanda eléctrica por horas y la necesidad de incorporar componentes estacionales en los modelos ARIMA.




Figura 3.3: Evolución de la demanda eléctrica durante los meses de febrero de 2019 hasta finales de abril de 2019

Se puede observar en la Figura 3.3 una clara estacionalidad semanal en la serie, se repiten patrones cada semana de lunes a domingo, es notable el descenso en la demanda en los fines de semana ya que es cuando menor actividad profesional y personal hay.




Figura 3.4: Evolución de la demanda eléctrica en España durante una semana representativa.

Es interesante ver cómo el fin de semana el consumo eléctrico es menor, además en la gráfica se puede apreciar como los domingos 10 y 17 de marzo de 2019 tienen una demanda eléctrica muy

similar, acorde con esa estacionalidad semanal que se ha detectado previamente.

3.3.2. Preparación del modelo

A la hora de comprobar todas y cada una de las 24 horas se observan valores atípicos para algunos días en algunas horas. Esto se corresponde concretamente con los cambios de hora que se producen los meses de marzo y de octubre a raíz del inicio del horario de verano y de invierno respectivamente.

A continuación se muestran ejemplos de dichas horas:




Figura 3.5: Valores atípicos y errores en la demanda eléctrica a las 2:00 h




Figura 3.6: Valores atípicos y errores en la demanda eléctrica a las 3:00 h

Como se puede ver en la Figura 3.5 y en la Figura 3.6, en la base de datos en algunas ocasiones

se ha quedado vacía esa hora y en otra se han solapado las horas, sumándose.

La fechas en las que se producen este tipo de error son:

- 30 de octubre de 2011
- 28 de octubre de 2012
- 27 de octubre de 2013
- 25 de octubre de 2015
- 30 de octubre de 2016
- 29 de octubre de 2017
- 28 de octubre de 2018
- 27 de marzo de 2011
- 25 de marzo de 2012
- 31 de marzo de 2013
- 30 de marzo de 2014
- 29 de marzo de 2015
- 27 de marzo de 2016
- 26 de marzo de 2017
- 25 de marzo de 2018

Para solucionarlo se han optado por una solución concreta según el tipo de fallo:

1. Para el error debido a la inexistencia de demanda en esa hora (valor igual a 0): Se ha extrapolado y se ha calculado la demanda para dicha hora como la media aritmética entre la hora anterior y la hora posterior.
2. Para los errores por horas solapadas: Se ha dividido la hora entre dos como aproximación para la demanda en esa hora.

Realizado este cambio y atendiendo a la teoría de series temporales se ha procedido a estabilizar la varianza y la media para poder hacer la serie estacionaria.

Nótese que las transformaciones aplicadas a la serie original determinan la serie final sobre la que se llevarán a cabo los cálculos posteriores, en particular el ajuste y la estimación de los parámetros del modelo ARIMA.

Por tanto, para todo esto se usará la demanda para la hora 10 ya que esta hora es una de las más difíciles y que mayores errores da para los modelos de series temporales.




Figura 3.7: Demanda de la hora que se va a tomar para el cálculo del modelo




Figura 3.8: Transformación logarítmica de la demanda eléctrica a las 10:00

Esta transformación lo que provoca es una reducción en la varianza, es decir una reducción en la heterocedasticidad. De hecho en la Figura 3.8 puede verse que los picos, aunque tengan la misma forma, son de una magnitud mucha menor que los de la Figura 3.7.




Figura 3.9: Primera diferencia de la demanda eléctrica (en logaritmos) a las 10:00

Esta diferenciación sirve para eliminar la tendencia (hacer la serie estacionaria en media). Viendo la Figura 3.9, se puede considerar que se tiene una serie estacionaria en media y varianza, lo siguiente es analizar las funciones de autocorrelación.

3.3.3. Funciones de autocorrelación

Obtenida la serie a trabajar se pueden graficar las funciones de autocorrelación simple (ACF) y de autocorrelación parcial (PACF), así será posible elegir los parámetros del modelo.




Figura 3.10: Funciones de autocorrelación parcial (PACF) y autocorrelación simple (ACF) de la serie diferenciada

La información que se puede obtener gracias a la función de autocorrelación simple (ACF) es que en los diferentes retrasos cada 7 lags hay una repetición de los mismos, esto se explica precisamente por la estacionalidad semanal (cada 7 días) que se apreció ya gráficamente en los apartados anteriores.

Por eso mismo es necesario realizar una diferenciación más pero está es de tipo estacional (en este caso cada 7 días) ya que lo que se va a restar (diferenciar) son los valores que se están repitiendo estacionalmente.

Así es como quedarían las nuevas funciones de autocorrelación simple y parcial, con este cambio




Figura 3.11: Funciones de autocorrelación parcial (PACF) y autocorrelación simple (ACF) de la serie diferenciada

3.3.4. Parámetros del modelo

Atendiendo a la Figura 3.11 podemos estimar los siguientes parámetros, además de las diferenciaciones ya realizadas.

Sobre el orden de la autorregresión:

- Fijándose en la función parcial de autocorrelación, PACF, no se aprecia ningún corte brusco después de p lags, ni mirando los lags estacionales ni los regulares (no estacionales) por lo que podemos considerar nulo el término autorregresivo.
- Además mirando la ACF no se observa que vaya desvaneciéndose lentamente, reforzando la idea de que es nulo el término autorregresivo

Sobre el orden de la media móvil:

- Fijándose en la función simple de autocorrelación, ACF, podemos apreciar un corte brusco después de $Q=1$ lag estacionales (podría llegar a considerarse un posible $Q=2$ por el lag 14)y en los regulares puede apreciarse un corte rápido en $q=1$ o en $q=2$ lags
- Además mirando la PACF puede apreciarse un desvanecimiento lento, lo que refuerza esta idea de $q=1$ y $q=2$

Por todo ello podemos considerar los siguientes modelos para la hora 10.

Tabla 3.1: Comparación de modelos ARIMA para la hora 10

Modelo	MAPE	Varianza residuos	AIC
ARIMA(0,1,1)(0,1,1)[7]	0.3173	0.003586	-14646.15
ARIMA(0,1,1)(0,1,2)[7]	0.3183	0.003538	-14715.88
ARIMA(0,1,2)(0,1,1)[7]	0.3089	0.003428	-14880.92
ARIMA(0,1,2)(0,1,2)[7]	0.3084	0.003381	-14951.01

Se ha seleccionado para cada uno de los modelos el MAPE, Error Porcentual Absoluto Medio, que mide en términos de porcentaje, cómo de lejos están las predicciones de los valores reales[13].

La varianza del error residual que mide cuánta variabilidad queda sin explicar por el modelo, por tanto cuanto mas baja sea mejor será el ajuste.

Además se ha tenido en cuenta el AIC (Criterio de Información de Akaike), el cual valora el ajuste del modelo en función de su complejidad[14].

Un tema muy importante a tener en cuenta es el sobreajuste[15] y es que no necesariamente un modelo ARIMA más ajustado y preciso, con menores errores,etc. tiene porque ser mejor.

Un modelo sobreajustado con muchos parámetros p, q (los cuales pueden llegar a ser estadísticamente hablando poco significativos) puede fallar en sus predicciones futuras, tiene un mayor coste computacional y genera una falsa sensación de precisión.

Por eso mismo el modelo que se ha decidido implementar es:

$$\boxed{\text{ARIMA}(0, 1, 2)(0, 1, 1)[7]}$$

Para este modelo y para esta hora:

Tabla 3.2: Estimación de parámetros del modelo ARIMA para la hora 10

Parámetro	Estimación	Error Std.	z value	p value
ma1	-0.4370	0.0135	-32.37	$< 2,2 \times 10^{-16}***$
ma2	-0.2179	0.0141	-15.45	$< 2,2 \times 10^{-16}***$
sma1	-0.9892	0.0019	-520.63	$< 2,2 \times 10^{-16}***$

Con esos pvalor se puede decir que hay una altísima evidencia de que esos coeficientes afectan al modelo y son muy significativos.




Figura 3.12: Análisis de residuos del modelo : serie temporal de residuos, función de autocorrelación (ACF) e histograma con ajuste normal

De la Figura 3.12 se pueden sacar varias observaciones.

Sobre la primera gráfica, que relaciona los residuos y el tiempo, se puede decir que:

- Los residuos parecen fluctuar alrededor del 0, parecen aleatorios y sin grandes cambios de varianza
- Por otro lado se pueden observar algunos picos demasiado grandes

Sobre la segunda gráfica, que es la función de autocorrelación simple (ACF) de los residuos:

- Muchas de las barras se encuentran dentro de las líneas discontinuas azules (intervalo de confianza), eso es positivo ya que refuerza la idea de que los residuos están comportandose como ruido blanco.
- Aún así hay otras muchas barras que salen del intervalo de confianza lo que puede dar lugar a pensar que está existiendo una correlación en ciertos lags.
De hecho el lag 7 puede llegar a ser extraño ya que podría plantear la duda sobre si se está capturando correctamente la estacionalidad con este modelo.

Sobre la tercera gráfica, que es el histograma de los residuos (con la curva normal marcada):

- El histograma ciertamente está bastante centrado y tiene ciertos atisbos de distribución normal, lo cual es algo deseado ya que se busca ruido blanco (y esto es síntoma de ello).
- Aún así aún puede parecerse más a una distribución normal, y evitar residuos que aparecen en la cola o bien tantos tan centrados.

Además como se indicó en la Tabla 3.1 la varianza de los residuos es 0.003428, por lo que operando:

$$\sqrt{\hat{\sigma}_R^2} = \sqrt{0,003428} = 0,05855$$

Es decir, hay un 5.85 % de error cuadrático medio, lo cual no es muy alto para ser un modelo inicial y da una idea de su solidez.

3.3.5. Modelos para las 24 horas del día

Mediante un bucle se puede proceder para calcular los diferentes parámetros para cada uno de los 24 modelos, uno para cada hora del día, así como para poder comprobar los errores que estos puedan tener.

Se obtienen los siguientes resultados:

Tabla 3.3: Parámetros estimados y errores del modelo ARIMA para cada hora del día

Hora	ma1	ma2	sma1	MAPE	$\hat{\sigma}_R^2$
1	-0.0154	-0.2081	-0.9833	0.162079	0.0005758
2	-0.0756	-0.1659	-0.9817	0.1616362	0.0005783
3	-0.0383	-0.1852	-0.9839	0.159701	0.0005602
4	0.0383	-0.2236	-0.9859	0.1586328	0.0005423
5	0.1083	-0.2581	-0.9856	0.1564592	0.0005214
6	0.1220	-0.3041	-0.9861	0.1613847	0.0005693
7	-0.1568	-0.3076	-0.9899	0.2142078	0.001266
8	-0.3213	-0.2775	-0.9976	0.2968305	0.002805
9	-0.4003	-0.2509	-0.9915	0.337925	0.003916
10	-0.4370	-0.2179	-0.9892	0.3089032	0.003428
11	-0.4190	-0.2138	-0.9871	0.2938237	0.002797
12	-0.3880	-0.2208	-0.9866	0.2898028	0.002457
13	-0.3615	-0.2342	-0.9867	0.2938488	0.002397
14	-0.3420	-0.2381	-0.9869	0.2917789	0.002263
15	-0.3142	-0.2405	-0.9884	0.2856448	0.002107
16	-0.3209	-0.2381	-0.9901	0.3028169	0.002457
17	-0.3285	-0.2400	-0.9909	0.3134055	0.002666
18	-0.3230	-0.2450	-0.9889	0.3111622	0.002624
19	-0.2854	-0.2521	-0.9875	0.2909356	0.002216
20	-0.2275	-0.2623	-0.9872	0.2649123	0.001825
21	-0.1432	-0.3001	-0.9875	0.2355885	0.001411
22	-0.0596	-0.3314	-0.9903	0.1960554	0.0009932
23	-0.0016	-0.2885	-0.9911	0.1707683	0.0007524
24	0.0345	-0.2525	-0.9867	0.1622047	0.000609

Para tener una representación más amigable de estos valores se presenta a continuación las diferentes gráficas de los parámetros y de los errores del modelo para las diferentes horas.




Figura 3.13: Evolución horaria de los parámetros del modelo ARIMA para las 24 horas del día




Figura 3.14: Evolución horaria de los errores del modelo ARIMA para las 24 horas del día

Podemos obtener las siguientes conclusiones:

- Podemos ver que el parámetro estacional MA se mantiene bastante estable a lo largo de las horas por tanto el efecto estacional se puede considerar bastante homogéneo.
- Los parámetros no estacionales $ma1$, $ma2$ varían bastante con la hora, lo que puede sugerir que la dinámica a lo largo del día no es uniforme.

- Hay una clara dependencia horaria en los errores, de forma que en las horas principales del día, las de mayor consumo, son las que peor pueden ajustarse, y son por tanto más difíciles de predecir.
- La hora con mayor MAPE y desviación típica es a las 9 de la mañana, siendo también alto a las 20h.
- La hora con menor MAPE y desviación típica es la de la 1 de la mañana, siendo en el horario nocturno bastante estable, lo que indica que es bastante previsible.

3.3.6. Fórmula del modelo

Para finalizar esta sección, se escriben los términos del modelo ARIMA, para estas expresiones algebraicas y esta síntesis matemática, se ha hecho uso de diferentes manuales de series temporales [16] [17].

La fórmula general para estos modelos es:

$$\phi_p(B) \Phi_P(B^s) (1 - B)^d (1 - B^s)^D y_t = \theta_q(B) \Theta_Q(B^s) w_t$$

De donde se puede simplificar y añadir lo siguiente:

- B : operador retardo, que se define como $B^k y_t = y_{t-k}$.
- $\phi_p(B)$: término autorregresivo regular nulo.
- $\Phi_P(B^s)$: término autorregresivo estacional nulo.
- $\theta_q(B) = (1 + \theta_1 B + \theta_2 B^2 + \dots + \theta_q B^q)$, polinomio de media móvil de grado q correspondiente a la parte regular del modelo, estos coeficientes $\theta_1, \theta_2, \dots, \theta_q$ son desconocidas y distintas para cada hora del día, se obtienen a partir de la estimación de dichos parámetros.
- $\Theta_Q(B^s) = (1 + \Theta_1 B^s + \Theta_2 B^{2s} + \dots + \Theta_Q B^{Qs})$, polinomio de media móvil de orden Q asociado a la parte estacional del modelo. Los coeficientes $\Theta_1, \Theta_2, \dots, \Theta_Q$ son desconocidos y diferentes para cada uno de los 24 modelos horarios, se obtienen a partir de la estimación de dichos parámetros.
- $(1 - B)^d$: operador de diferenciación no estacional, que indica el número d de diferenciaciones aplicadas para eliminar la tendencia y hacer estacionaria la serie.
- $(1 - B^s)^D$: operador de diferenciación estacional, que indica las D diferenciaciones estacionales utilizadas para eliminar patrones periódicos de periodo s .
- y_t : serie temporal observada de la demanda eléctrica en el instante t , que en este caso es $\log(z_t)$.
- w_t : término de error aleatorio o ruido blanco, con media cero y varianza constante.

En el caso de la hora 10, sustituyendo los parámetros quedaría algo así:

$$(1 - B)(1 - B^7) \log(z_t) = (1 - 0,437 B - 0,2179 B^2) (1 - 0,9892 B^7) w_t$$

4. MODELIZACIÓN Y ESTIMACIÓN

Como se ha visto en el apartado anterior con el modelo ARIMA estimado existen errores y una varianza residual, lo cual tiene sentido ya que hay otros factores que sirven para explicar el modelo, estas variables explicativas son los regresores que usaremos en el modelo. Por eso a partir de ahora el modelo es un Reg-ARIMA

Sobre un Reg-ARIMA(0, 1, 2)(0, 1, 1)[7] se añadirán los siguientes regresores:

- Festivos: afectan la demanda de electricidad por el cambio en las rutinas de las personas así como la reducción de la actividad industrial
- Temperatura: influye en el uso de sistemas de calefacción o refrigeración, especialmente en situaciones de temperaturas extremas.
- Radiación: puede influir en la demanda eléctrica tanto de forma indirecta, como de forma directa mediante el aumento del autoconsumo fotovoltaico.

Será sobre este último regresor sobre el que se hará un estudio más exhaustivo con el fin de analizar en mayor profundidad como podría estar afectando a la demanda.

4.1. Modelo Reg- ARIMA con festivos

Ha sido proporcionada una matriz de regresores en la cual hay multitud de regresores y no todos son de interés. Por tanto se procede a crear una nueva matriz en la que incluya los siguientes festivos nacionales:

- 6 de enero: Día de Reyes
- 1 de mayo: Día del Trabajo
- 15 de agosto: Asunción de la Virgen
- 12 de octubre: Día de la Hispanidad
- 1 de noviembre: Día de todos los Santos
- 6 de diciembre: Día de la Constitución
- 24 de diciembre: Día de Nochebuena
- 31 de diciembre: Día de Nochevieja

Además se han creado e incluido las siguientes variables, ya que aunque no estuviesen en la matriz de regresores iniciales, sí que son días festivos en los que la demanda puede verse alterada:

- 25 de diciembre: Día de Navidad
- 1 de enero: Día de Año Nuevo
- 8 de diciembre: Día de la Inmaculada Concepción
- Viernes Santo

Nótese que las variables usadas para representar los festivos son binarias, es decir que tomaron el valor 1 solo en la fecha correspondiente, sino su valor es 0.

Para poder abarcar y completar en mayor profundidad este apartado se ha introducido otra columna a la matriz en la que están el resto de festividades particulares de las diferentes regiones de la geografía española.

Dichas variables se encuentran en la fecha concreta de la festividad regional y toman el valor entre 0 y 1 en función del porcentaje de la población afectada por dicha festividad.

Además cabe resaltar que hubo que modificar la columna de la base de datos de las festividades regionales para eliminar las celdas con valor 1 ya que en realidad eso representa una festividad nacional la cual ya está representada por su propia columna destinada a esa festividad en concreto.

4. MODELIZACIÓN Y ESTIMACIÓN

	fest_nac_06EN	fest_nac_01MY	fest_nac_15AG	fest_nac_12OC	fest_nac_01NO	fest_nac_06DI	fest_nac_24DI	fest_nac_31DI	fest_nac_25DI	fest_nac_01EN	fest_nac_08DI	fest_nac_VS	fest_regionales
1	0	0	0	0	0	0	0	0	0	1	0	0	0.000
2	0	0	0	0	0	0	0	0	0	0	0	0	0.000
3	0	0	0	0	0	0	0	0	0	0	0	0	0.000
4	0	0	0	0	0	0	0	0	0	0	0	0	0.000
5	0	0	0	0	0	0	0	0	0	0	0	0	0.000
6	1	0	0	0	0	0	0	0	0	0	0	0	0.000
7	0	0	0	0	0	0	0	0	0	0	0	0	0.058
8	0	0	0	0	0	0	0	0	0	0	0	0	0.000
9	0	0	0	0	0	0	0	0	0	0	0	0	0.000
10	0	0	0	0	0	0	0	0	0	0	0	0	0.000
11	0	0	0	0	0	0	0	0	0	0	0	0	0.000
12	0	0	0	0	0	0	0	0	0	0	0	0	0.000
13	0	0	0	0	0	0	0	0	0	0	0	0	0.000
14	0	0	0	0	0	0	0	0	0	0	0	0	0.000
15	0	0	0	0	0	0	0	0	0	0	0	0	0.000
16	0	0	0	0	0	0	0	0	0	0	0	0	0.000
17	0	0	0	0	0	0	0	0	0	0	0	0	0.000
18	0	0	0	0	0	0	0	0	0	0	0	0	0.000
19	0	0	0	0	0	0	0	0	0	0	0	0	0.000
20	0	0	0	0	0	0	0	0	0	0	0	0	0.018
21	0	0	0	0	0	0	0	0	0	0	0	0	0.000
22	0	0	0	0	0	0	0	0	0	0	0	0	0.063

Figura 4.1: Estructura de las variables indicadoras de festivos nacionales y regionales utilizadas como regresores en el modelo

Analizando el modelo para ver la mejora que de este regresor pueda estar implementando se muestra a continuación los MAPE y las varianzas de los residuos:

Tabla 4.1: Errores de predicción del modelo ARIMA por hora del día: MAPE y varianza residual

Hora	MAPE	Varianza residual
1	0.1612606	0.0005479
2	0.1608173	0.0005464
3	0.1590209	0.0005302
4	0.1579167	0.0005175
5	0.1539304	0.0004865
6	0.1506182	0.0004525
7	0.1690397	0.0005963
8	0.2185156	0.0010930
9	0.2361150	0.0013280
10	0.2022312	0.0010030
11	0.1978716	0.0008903
12	0.2078357	0.0009329
13	0.2181674	0.0010160
14	0.2202928	0.0010150
15	0.2172371	0.0009712
16	0.2249741	0.0010460
17	0.2304725	0.0011050
18	0.2285124	0.0010880
19	0.2192952	0.0009785
20	0.1996821	0.0008278
21	0.1803653	0.0006743
22	0.1554581	0.0004869
23	0.1376511	0.0003740
24	0.1362150	0.0003516

De forma más visual:




Figura 4.2: Comparación del MAPE horario del modelo ARIMA con y sin incorporación de festivos




Figura 4.3: Evolución horaria del error medio del modelo ARIMA con incorporación de festivos

Se puede observar que:

- En las horas nocturnas como son sobre todo de 1 a 5 de la mañana, la mejora del modelo es bastante reducida.
- En las horas centrales del día la mejora es considerable, mientras que en el modelo original el error medio a las 9 de la mañana era del 6,26 %, añadiendo el regresor de los días festivos,

ha disminuido hasta el 3,64%.

Esto es consistente ya que la curva de la demanda eléctrica suele ser tener la misma forma sea o no festivo para esas horas de la madrugada y bastante diferente en la horas diurnas.




Figura 4.4: Comparación de la demanda eléctrica horaria entre días festivos y no festivos

En relación con esto se puede observar como la adicción de regresores festivos como pueden ser el Día de Nochebuena, Navidad o por ejemplo el Día de Reyes no son significativos para los modelos Reg-ARIMA a esas horas de la madrugada mientras que sí los son en las horas puntas.

```

--- Hora 2 ---
Call:
arima(x = log(bh), order = c(0, 1, 2), seasonal = list(order = c(0, 1, 1), period = 7),
      xreg = matriz_festivos)

Coefficients:
ma1      ma2      sma1  fest_nac_06EN  fest_nac_01MY  fest_nac_15AG  fest_nac_12OC  fest_nac_01NO  fest_nac_06DI  fest_nac_24DI  fest_nac_31DI
0.0121  -0.2168  -0.9812  0.0039      0.0284      0.0136      0.0195      0.0226      0.0220  -0.0034      0.0145
s.e.    0.0154  0.0157  0.0027  0.0041      0.0042      0.0043      0.0043      0.0044  0.0055      0.0054

fest_nac_25DI  fest_nac_01EN  fest_nac_08DI  fest_nac_VS  fest_regionales
0.0037      0.0624      0.0180     -0.0192     -0.0108
s.e.    0.0056      0.0055      0.0044      0.0048      0.0039

sigma^2 estimated as 0.0005464:  log likelihood = 12272.25,  aic = -24510.49

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.000118025 0.02336139 0.01619161 -0.001437868 0.1608173 0.475726 0.01892596

```

Figura 4.5: Resultados del modelo ARIMA con regresores festivos para las 2 de la mañana

Regla práctica (habitualmente empleada en trabajos académicos)[18]:

$$|t| \gtrsim 2 \implies \text{coeficiente estadísticamente significativo}$$

No es el caso de estos regresores para esas horas concretas

```

--- Hora 6 ---
call:
arima(x = log(bh), order = c(0, 1, 2), seasonal = list(order = c(0, 1, 1), period = 7),
      xreg = matriz_Festivos)

Coefficients:
      ma1      ma2      sma1 fest_nac_06EN fest_nac_01MY fest_nac_15AG fest_nac_12OC fest_nac_01NO fest_nac_06DI fest_nac_24DI fest_nac_31DI
0.0789 -0.2415 -0.9838      -0.0575      -0.0402      -0.0162      -0.0253      -0.0337      -0.0232      -0.0314      -0.0139
s.e.    0.0150    0.0151    0.0023      0.0036      0.0037      0.0037      0.0037      0.0037      0.0038      0.0050      0.0049
      fest_nac_25DI fest_nac_01EN fest_nac_08DI fest_nac_VS fest_regionales
      -0.089      -0.0463      -0.0223      -0.0783      -0.0759
s.e.      0.005      0.0049      0.0039      0.0042      0.0034

sigma^2 estimated as 0.0004525:  log likelihood = 12767.43,  aic = -25500.86

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -9.368467e-05 0.02125953 0.01505077 -0.001239757 0.1506182 0.3344061 0.01408026

```

Figura 4.6: Resultados del modelo ARIMA con regresores para las 6 de la mañana

Para la hora 6 ya todos los regresores son muy significativos, lo cual tiene sentido ya que a partir de las 5 o 6 de la mañana se puede percibir una diferencia notable en los hábitos de las personas e industrias para días festivos o no festivos.

Para finalizar se podría decir que matemáticamente se ha añadido la siguiente fórmula

$$\log(z_{t,h}) = \alpha_0 + \sum_j \beta_j \text{Festivo}_t^{(j)} + w_{t,h}$$

De este modo, la demanda se modela como una combinación de un término constante y un conjunto de coeficientes que capturan desviaciones sistemáticas respecto a un día laborable estándar, quedando el resto de la variabilidad recogida en el término de error.

Esta formulación permite aislar el impacto estructural de los festivos sobre la demanda eléctrica, facilitando una interpretación clara de dichos efectos y reduciendo la carga explicativa que debe asumir el componente estocástico del modelo. En consecuencia, el proceso ARIMA actúa sobre una serie residual más estable, mejorando el ajuste global del modelo.

Este enfoque sienta la base para la posterior incorporación de variables térmicas, permitiendo evaluar de forma incremental la contribución de los distintos factores explicativos.

4.2. Modelo Reg-ARIMA con temperatura

Una vez incorporadas los festivos, se procede con las temperaturas como regresores adicionales. Como se explicó al principio, es previsible una relación entre la demanda de electricidad y las condiciones térmicas.

Para ello haremos uso de la base de datos correspondiente a las condiciones climáticas.




Figura 4.7: Relación entre la temperatura y la demanda eléctrica en la hora 10

Aunque no sea de especial relevancia para el desarrollo y la modelización de la demanda se puede comentar que existe una diferencia en esa demanda según los días de la semana, segmentando en días laborales, sábados y domingos.




Figura 4.8: Relación entre temperatura y demanda eléctrica en la hora 10 diferenciando días laborables, sábados y domingos

Se procede estandarizando las variables $T_{\min}$ y $T_{\max}$, ya que a la hora de usarlas como regresores se quiere evitar que los coeficientes estimados no estén, en mayor o menor medida, afectados por la escala de la variable así como para favorecer la homogeneidad numérica en el modelo.

Además se han creado los cuadrados de las temperaturas, con esto lo que se persigue es poder también capturar las relaciones no lineales entre temperatura y demanda como se puede ver en la imagen, esto tiene sentido ya que cuando las temperaturas son suaves prácticamente nadie enciende los dispositivos de climatización y sin embargo cuando las temperaturas son extremas (tanto muy altas como muy bajas) todo el mundo hace uso de ellos.

Las transformaciones realizadas son:

- **Normalización de la temperatura mínima:**

$$z_{\min} = \frac{T_{\min} - \min(T_{\min})}{\max(T_{\min}) - \min(T_{\min})}$$

- **Normalización de la temperatura máxima:**

$$z_{\max} = \frac{T_{\max} - \min(T_{\max})}{\max(T_{\max}) - \min(T_{\max})}$$

- **Cuadrado de las variables normalizadas:**

$$z_{\min}^2 = \left(\frac{T_{\min} - \min(T_{\min})}{\max(T_{\min}) - \min(T_{\min})} \right)^2$$

$$z_{\max}^2 = \left(\frac{T_{\max} - \min(T_{\max})}{\max(T_{\max}) - \min(T_{\max})} \right)^2$$

A continuación se analizan los resultados obtenidos al incluir este regresor, evaluando su impacto sobre el error de predicción en función de la hora del día.




Figura 4.9: Evolución del MAPE por hora del día para los distintos modelos considerados




Figura 4.10: Evolución del parámetro σ por hora del día para los distintos modelos considerados

Se puede observar lo siguiente:

- En las horas nocturnas la mejora es mínima.
- En las horas centrales del día si que se nota una mayor mejora, cuando los regresores eran los festivos el error medio máximo (a las 9) era del 3,64 % , ahora el error es de 3,56 %.
- Por otro lado los MAPE se han reducido en mayor medida, siendo en prácticamente la totalidad de los 24 modelos menor del 20 % , lo cual indica la solidez del mismo.

Es importante resaltar, como se ve en la siguiente figura, que las temperaturas máximas en las horas de la madrugada no son significativas.

Esto tiene mucho sentido ya que si es invierno las temperaturas máximas no son suficientemente altas como para encender el aire acondicionado; y en verano, las temperaturas máximas, a esas horas, son los suficientemente bajas como para que tampoco haya que usarlo.

Esto provoca que los regresores zmax y z2max no sean significativos entre las 1 y las 9 de la mañana, ya que no explican la demanda a esas horas.

```

--- Hora 2 ---

Call:
arima(x = log(bh), order = c(0, 1, 2), seasonal = list(order = c(0, 1, 1), period = 7),
      xreg = matriz_festytem)

Coefficients:
      ma1      ma2      sma1 fest_nac_06EN fest_nac_01MY fest_nac_15AG fest_nac_120C fest_nac_01NO
-0.0712 -0.2391 -0.9811      0.0028      0.0256      0.0128      0.0155      0.0208
s.e.    0.0159  0.0153  0.0027      0.0042      0.0043      0.0043      0.0043      0.0044
      fest_nac_06DI fest_nac_24DI fest_nac_31DI fest_nac_25DI fest_nac_01EN fest_nac_08DI fest_nac_VS
      0.0211      -0.0058      0.0112      -0.0025      0.0557      0.0162      -0.0243
s.e.    0.0044      0.0054      0.0053      0.0055      0.0054      0.0044      0.0048
      fest_regionales zmax zmin zmax2 zmin2
      -0.0141      -0.0148      -0.3006      0.0087      0.3549
s.e.    0.0039      0.0208      0.0204      0.0195      0.0202

sigma^2 estimated as 0.0005093: log likelihood = 12456.97, aic = -24871.95

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.0001198876 0.02255501 0.01545886 -0.001493032 0.1535732 0.454197 0.01975371

```

Figura 4.11: Resultados del modelo ARIMA con regresores festivos y térmicos para la hora 2

A partir de las 10 de la mañana todos los regresores son significativos ya que tanto las temperaturas máximas como las mínimas tienen una fuerte influencia.

```

--- Hora 14 ---

Call:
arima(x = log(bh), order = c(0, 1, 2), seasonal = list(order = c(0, 1, 1), period = 7),
      xreg = matriz_festytem)

Coefficients:
      ma1      ma2      sma1 fest_nac_06EN fest_nac_01MY fest_nac_15AG fest_nac_120C fest_nac_01NO
-0.3769 -0.1865 -0.968      -0.2063      -0.1760      -0.1450      -0.1405      -0.1572
s.e.    0.0141  0.0144  0.007      0.0061      0.0061      0.0063      0.0063      0.0063
      fest_nac_06DI fest_nac_24DI fest_nac_31DI fest_nac_25DI fest_nac_01EN fest_nac_08DI fest_nac_VS
      -0.0985      -0.0902      -0.0718      -0.2307      -0.2538      -0.1046      -0.2242
s.e.    0.0063      0.0069      0.0069      0.0070      0.0067      0.0063      0.0064
      fest_regionales zmax zmin zmax2 zmin2
      -0.2054      -0.6535      -0.1756      0.5503      0.3441
s.e.    0.0053      0.0256      0.0251      0.0240      0.0245

sigma^2 estimated as 0.0007969: log likelihood = 11282.52, aic = -22523.05

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -4.653311e-05 0.02821016 0.01963549 -0.001037092 0.1904953 0.2488723 0.004215276

```

Figura 4.12: Resultados del modelo ARIMA con regresores festivos y térmicos para la hora 14

Para finalizar este apartado, se añade la fórmula matemática:

$$\log(z_{t,h}) = \alpha_0 + \sum_j \beta_j \text{Festivo}_t^{(j)} + \alpha_1 \widetilde{\text{Temp}}_t + \alpha_2 \widetilde{\text{Temp}}_t^2 + w_{t,h}$$

En esta expresión, los términos asociados a las variables indicadoras de festivos recogen los desplazamientos estructurales de la demanda respecto a un día laborable estándar, mientras que los regresores térmicos lineales y cuadráticos permiten modelar la relación no lineal entre temperatura y consumo eléctrico.

De este modo, el término de error concentra únicamente la variabilidad no explicada por estos factores, lo que facilita su modelización mediante un proceso ARIMA estacional.

4.3. Modelo Reg-ARIMA con radiación

Finalmente, para perfeccionar el modelo, se ha incorporado otro regresor: la radiación solar en la península, con el fin de mejorar la explicación del modelo Reg-ARIMA.

El objetivo de añadir este regresor es el de poner de manifiesto la idea del autoconsumo así como su creciente instalación en viviendas particulares, solares, industrias, etc.

De esta forma se procede a estudiar si existe un impacto significativo en la península sobre la demanda eléctrica a través del autoconsumo fotovoltaico.

Asimismo, se pretende estudiar más a fondo y desde diferentes perspectivas este regresor y sus coeficiente para arrojar luz sobre la influencia del mismo, ya que en cierto modo este es el mayor objetivo de este Trabajo de Fin de Grado.




Figura 4.13: Relación entre radiación solar y demanda eléctrica en la hora 10, diferenciando días laborables, sábados y domingos

En esta figura lo que se pretende visualizar es, por un lado, que las demandas son diferentes en función del día de la semana (como ya se sabía), y no tanto en función de la radiación, ya que por otro lado se puede ver que para un mismo tipo de día hay demanda eléctrica constante independientemente de la radiación solar que haya ese día.

Lo cual tiene sentido ya que, está graficando un periodo de años en los cuales no existía (y por tanto no podía afectar) el autoconsumo y por otro lado en muchas ocasiones este autoconsumo siempre aporta energía, lo que cambia es la cantidad de la misma que pueda aportar.

Para poder implementar en el modelo este regresor se ha estandarizado la variable (por las mismas razones que se estandarizaron en apartados anteriores), de la siguiente forma:

$$z_{\text{rad}} = \frac{\text{rad}_{\text{PENIN}} - \min(\text{rad}_{\text{PENIN}})}{\max(\text{rad}_{\text{PENIN}}) - \min(\text{rad}_{\text{PENIN}})}$$
$$z_{\text{rad}}^2 = \left(\frac{\text{rad}_{\text{PENIN}} - \min(\text{rad}_{\text{PENIN}})}{\max(\text{rad}_{\text{PENIN}}) - \min(\text{rad}_{\text{PENIN}})} \right)^2$$

Nótese que se ha creado la variable z_{rad}^2 para poder capturar posibles relaciones no lineales que pueda haber con la radiación solar.

Estas variables se han añadido a la matriz creada, junto al resto de regresores, y se han creado 24 modelos.

Debido a la importancia de este apartado para el Trabajo de Fin de Grado, se ha procedido a dibujar los coeficientes estimados por el modelo.




Figura 4.14: Evolución horaria de los coeficientes asociados a z_{rad} y z_{rad}^2

Podemos observar lo siguiente:

- En las horas sin luz, los coeficientes son practicamente nulos, por lo que el efecto de la radiación es limitado.
- En las horas diurnas, los coeficientes crecen exponencialmente respecto a los nocturnos.
- De las 12 a las 19, los coeficientes están en su máximo siendo casi 10 veces mayores que en las horas de la noche, teniendo valores similares.
- Los coeficientes, z_{rad} son negativos, debido a que este efecto disminuye el consumo.

```

--- Hora 2 ---

Call:
arima(x = log(bh), order = c(0, 1, 2), seasonal = list(order = c(0, 1, 1), period = 7),
      xreg = matriz_festytemyrad)

Coefficients:
      ma1      ma2      sma1 fest_nac_06EN fest_nac_01MY fest_nac_15AG fest_nac_120C fest_nac_01NO
-0.0722 -0.2388 -0.9811      0.0030      0.0259      0.0127      0.0152      0.0212
s.e.      0.0160      0.0153      0.0027      0.0042      0.0043      0.0043      0.0043      0.0044
fest_nac_06DI fest_nac_24DI fest_nac_31DI fest_nac_25DI fest_nac_01EN fest_nac_08DI fest_nac_vs
s.e.      0.0214      -0.0060      0.0109      -0.0028      0.0557      0.0165      -0.0252
      0.0044      0.0054      0.0053      0.0055      0.0054      0.0044      0.0048
fest_regionales zmax zmin zmax2 zmin2 zrad zrad2
s.e.      -0.0145 -0.0035 -0.3152 0.0098 0.3559 -0.0246 0.0091
      0.0039      0.0212      0.0214      0.0201      0.0211      0.0102      0.0092

sigma^2 estimated as 0.0005081: log likelihood = 12463.23, aic = -24880.46

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.0001236083 0.0225282 0.0154356 -0.001530154 0.153341 0.4535135 0.02011057

```

Figura 4.15: Resultados del modelo ARIMA con regresores festivos, térmicos y de radiación para la hora 2

Es notable que en horas nocturnas, como las 2 de la mañana, los regresores sean poco significativos y presenten coeficientes prácticamente nulos. Y como en las horas en las que el Sol radia con mayor potencial estos coeficientes se vuelven más intensos y los regresores muy significativos.

```

--- Hora 16 ---

Call:
arima(x = log(bh), order = c(0, 1, 2), seasonal = list(order = c(0, 1, 1), period = 7),
      xreg = matriz_festytemyrad)

Coefficients:
      ma1      ma2      sma1 fest_nac_06EN fest_nac_01MY fest_nac_15AG fest_nac_120C fest_nac_01NO
-0.3117 -0.2184 -0.9766      -0.2182      -0.1929      -0.1267      -0.1547      -0.1537
s.e.      0.0140      0.0141      0.0038      0.0057      0.0057      0.0058      0.0058      0.0058
fest_nac_06DI fest_nac_24DI fest_nac_31DI fest_nac_25DI fest_nac_01EN fest_nac_08DI fest_nac_vs
s.e.      -0.1013      -0.0961      -0.0736      -0.2775      -0.2556      -0.1037      -0.225
      0.0059      0.0066      0.0065      0.0066      0.0064      0.0059      0.006
fest_regionales zmax zmin zmax2 zmin2 zrad zrad2
s.e.      -0.2163 -0.5289 -0.3899 0.5775 0.4166 -0.2983 0.1812
      0.0050      0.0255      0.0258      0.0241      0.0251      0.0131      0.0116

sigma^2 estimated as 0.0007228: log likelihood = 11537.64, aic = -23029.28

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -4.902543e-05 0.0268685 0.01869697 -0.001055757 0.18228 0.2389753 0.008182046

```

Figura 4.16: Resultados del modelo ARIMA con regresores festivos, térmicos y de radiación para la hora 16

A continuación se estudian los resultados obtenidos tras incorporar el regresor de radiación, analizando cómo afecta a la capacidad predictiva del modelo en las distintas horas del día.




Figura 4.17: Evolución del MAPE por hora del día para los distintos modelos considerados




Figura 4.18: Evolución del parámetro σ por hora del día para los distintos modelos considerados

Lo que se puede concluir al añadir el regresor radiación es lo siguiente:

- La radiación aporta una mejora adicional, de menos magnitud y concentrada en franjas horarias.
- La reducción simultánea del MAPE y del error indica una mejora estructural del modelo (no solo algo puntual).
- El modelo final ofrece un buen equilibrio entre precisión y estabilidad a lo largo del día.

La siguiente formulación recoge la especificación final del modelo de demanda horaria empleada en este estudio. La variable dependiente se expresa en logaritmos para estabilizar la varianza y facilitar la interpretación de los coeficientes.

$$\log(y_{t,h}) = \alpha_0 + \alpha_1 \widetilde{\text{Temp}}_t + \alpha_2 \widetilde{\text{Temp}}_t^2 + \sum_j \beta_j \text{Festivo}_t^{(j)} + \delta \widetilde{\text{Rad}}_t + w_{t,h}$$

La inclusión de la temperatura en forma lineal y cuadrática permite modelar la relación no lineal observada entre las condiciones térmicas y la demanda eléctrica, capturando incrementos tanto en situaciones de frío como de calor extremos. Los efectos de calendario se introducen mediante variables indicadoras de festivos, que recogen cambios estructurales en los patrones de consumo respecto a los días laborables.

Finalmente, la radiación solar se incorpora como un factor adicional de influencia indirecta sobre la demanda, mientras que la dinámica temporal restante queda absorbida por el término de error w , modelado mediante un proceso ARIMA estacional.

4.3.1. Diagnóstico y validación del modelo

Seguidamente, se evalúa el modelo mediante un análisis ligeramente más profundo de los residuos con los festivos, temperatura y radiación.




Figura 4.19: Diagnóstico de residuos del modelo $\text{ARIMA}(0,1,2)(0,1,1)[7]$: serie temporal de residuos, función de autocorrelación y distribución

Respecto al modelo original sin regresores, se aprecian las siguientes mejoras:

- Reducción notable de los valores atípicos extremos en la serie temporal de los residuos (los picos de gran magnitud han disminuido).
- Importante disminución de autocorrelaciones significativas en la función ACF, ahora la mayoría de los retardos se encuentran dentro de las bandas de confianza.
- La estructura residual es más cercana al ruido blanco (lo que indica una mejor captura de la serie por parte del modelo).
- La distribución de los residuos es ligeramente más próxima a la normal.

Además se ha comprobado la significatividad estadística de los coeficientes estimados en el modelo Reg-ARIMA y todos los parámetros presentan pvalores muy inferiores al nivel de significación de $\alpha=0,05$ lo que indica que explican el modelo aportando información relevante al mismo.

4.3.2. Regresor Radiación y coeficientes

Se debe resaltar algo muy importante y es que todos los coeficientes estimados para cada una de las 24 horas representan los efectos medios calculados a partir de la muestra temporal disponible (es decir, desde el 1 de enero de 2011).

Esto es muy positivo para analizar la realidad de la influencia de las temperaturas y los festivos ya que en los 14 años analizados siempre ha habido los mismos festivos y temperaturas muy similares y ambos afectaban en magnitudes similares en todo este periodo.

De la misma forma, esto no está permitiendo analizar bien del todo el efecto de la radiación, ya que el objetivo último de este efecto es su relación con el autoconsumo siendo este el que realmente afecta a la demanda de electricidad, y por tanto pudiendo ser realmente significativo y factor explicativo en la demanda de los últimos años, que es cuando realmente se ha implementado esta tecnología a mayor escala.

Los coeficientes en los 24 modelos horarios del regresor radiación no son otra cosa que el efecto medio de cuando no había autoconsumo, y por tanto no era variable explicativa, y de cuando sí que se ha implementado el autoconsumo, y si que ha empezado a ser explicativa, como en los últimos años.

Por tanto, si lo que se pretende es realizar una análisis más fidedigno de este regresor, se deberán obtener coeficientes por periodos temporales más segmentados, como puede ser por años, por semestres o trimestres, por meses, etc.

Para cubrir el alcance de este Trabajo de Fin de Grado se va a analizar este regresor y sus coeficientes en periodos de trimestres.

$$\log(z_{t,h}) = \alpha_0 + \sum_q \delta_q (\text{Rad}_t \cdot 1_{t \in \text{Trimestre } q}) + \text{resto de regresores} + w_{t,h}$$

Para ello lo que se han realizado los siguientes pasos:

- A partir de las fechas de base de datos general se crean los trimestres, eliminando los anteriores a 2021 (ya que lo que se pretende analizar es a partir del 1 de enero de 2021).
- Estas variables se transforman en “factor”, creando un nivel específico para cada trimestre analizado.
- Se generan variables de interacción entre el trimestre y la radiación (no es otra cosa que la radiación se multiplique por 1 en su día de su trimestre).
- De la matriz original de regresores se eliminan zrad y zrad2 para poder poner ahora la radiación por trimestres (se tratar de evitar poner dos veces lo mismo).
- Con la matriz con todos los regresores ahora se crea un bucle para generar los 24 modelos arimas para cada una de las horas.

4. MODELIZACIÓN Y ESTIMACIÓN




Figura 4.20: Matriz de regresores por trimestres. Visualización del cambio de la radiación solar normalizada entre trimestres, utilizada como variable explicativa en el modelo.

Lo que se ha obtenido es el coeficiente del regresor radiación para cada uno de los 18 trimestres, para cada una de las 24, a continuación se muestra en una tabla la hora 16:

Tabla 4.2: Coeficientes estimados por trimestre para la hora 16

Trimestre	Coeficiente hora 16
T1	-0,0889
T2	-0,0634
T3	-0,0663
T4	-0,1709
T5	-0,0586
T6	-0,0762
T7	-0,0837
T8	-0,1699
T9	-0,1763
T10	-0,1621
T11	-0,2030
T12	-0,2604
T13	-0,3957
T14	-0,2522
T15	-0,2274
T16	-0,3168
T17	-0,3611
T18	-0,3736

Graficamente se pueden ver los coeficientes de las 16,11 y 3 en la siguiente gráfica:




Figura 4.21: Evolución trimestral del coeficiente asociado a la radiación solar para las horas 16,11 y 3

Es muy llamativo ver lo siguiente:

- En las horas 11 y 16 las curvas de los coeficientes siguen formas similares.
- En la hora 3, representando las horas en las que no hay Sol, los coeficientes no siguen ningún patrón ni forma lógica y oscilan entorno al valor 0 ya que en horario nocturno, independientemente del trimestre e independientemente de la estructura fotovoltaica de España no hay autoconsumo.
- A lo largo de los años, mientras pasan los trimestres la magnitud de los coeficientes se va acentuando (pudiendo indicar una mayor implantación del autoconsumo en el país).
- Para cada año, formado por cuatro trimestres se cumple un ligero patrón en el cual en los trimestres fríos los coeficientes son más negativos que en los trimestres cálidos (de mayor radiación).

4. MODELIZACIÓN Y ESTIMACIÓN

```

--- Hora 3 ---

Call:
arima(x = log(bh), order = c(0, 1, 2), seasonal = list(order = c(0, 1, 1), period = 7),
xreg = xreg_total)

Coefficients:
    ma1      ma2     sma1 fest_nac_06EN fest_nac_01MY fest_nac_15AG fest_nac_12OC fest_nac_01NO fest_nac_06DI fest_nac_24DI fest_nac_31DI
-0.0391 -0.2562 -0.9830 -0.0096      0.0143      0.0104      0.0105      0.0127      0.0137     -0.0137      0.0050
s.e.      0.0159  0.0153  0.0025      0.0040      0.0041      0.0042      0.0042      0.0042      0.0043      0.0052
    fest_nac_25DI fest_nac_01EN fest_nac_08DI fest_nac_VS fest_regionales zmax zmin zmax2 zmin2 zrad:trimestre_2021_safe2021T1
-0.0099      0.0549      0.0098     -0.0322     -0.0240     -0.0092     -0.2906      0.0020      0.3413      0.0147
s.e.      0.0054      0.0053      0.0043      0.0047      0.0038      0.0206      0.0202      0.0193      0.0199      0.0226
    zrad:trimestre_2021_safe2021T2 zrad:trimestre_2021_safe2021T3 zrad:trimestre_2021_safe2021T4 zrad:trimestre_2021_safe2021T5
-0.0146      0.0174      0.0202      0.0693
s.e.      0.0174      0.0215      0.0325      0.0261
    zrad:trimestre_2021_safe2022T2 zrad:trimestre_2021_safe2022T3 zrad:trimestre_2021_safe2022T4 zrad:trimestre_2021_safe2022T5
-0.0268      0.0182      0.0425      0.0591
s.e.      0.0182      0.0215      0.0290      0.0268
    zrad:trimestre_2021_safe2023T2 zrad:trimestre_2021_safe2023T3 zrad:trimestre_2021_safe2023T4 zrad:trimestre_2021_safe2023T5
-0.0259      0.0191      0.0244      0.0154
s.e.      0.0191      0.0228      0.0297      0.0259
    zrad:trimestre_2021_safe2024T2 zrad:trimestre_2021_safe2024T3 zrad:trimestre_2021_safe2024T4 zrad:trimestre_2021_safe2024T5
-0.0478      0.0191      0.0096      0.0471
s.e.      0.0191      0.0221      0.0296      0.0157
    zrad:trimestre_2021_safe2025T2
0.0713
s.e.      0.0274

sigma^2 estimated as 0.0004924:  log likelihood = 12545.76,  aic = -25013.51

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.0001474979 0.02217574 0.01521192 -0.001774795 0.1519081 0.4466893 0.01709538

```

Figura 4.22: Coeficientes no significativos para la hora 3 en todos los trimestres

En relación al comentario de que se observan coeficientes de menor magnitud (en valor absoluto) en trimestres de verano que en invierno, es algo que puede parecer bastante antiintuitivo, pero tiene una explicación lógica:

$$\frac{\partial \log(z_{t,h})}{\partial zrad_t} = \delta_q$$

Con esta fórmula, lo que se deduce, es que el coeficiente no es otra cosa más que la variación del logaritmo de la demanda respecto de la variable estandarizada, no es el autoconsumo en sí, sino una sensibilidad marginal si se quiere ver así.

En verano la radiación es mucho mayor pero el efecto adicional por cada incremento de la radiación solar es menor, al revés que en invierno, donde la radiación es baja y cada incremento adicional tiene un impacto proporcional mayor (por eso el coeficiente sale más negativo).

4.3.3. Estimación del autoconsumo con la radiación

El siguiente paso para el análisis y contraste del regresor radiación y sus coeficientes sería darle utilidad.

La mejor forma de darle utilidad es precisamente comprobando que las estimaciones de autoconsumo, basadas en los parámetros del apartado anterior son consistentes y quedan valores coherentes y esperados.

Para ello partiendo de los coeficientes del apartado anterior se pueden escalar los datos de la siguiente manera:

$$\begin{aligned}
 & \text{Coeficientes } \delta_{h,q} \\
 & \quad \Downarrow \\
 & \delta_{h,q} \cdot \text{zrad}_d \\
 & \quad \Downarrow \\
 & \widehat{\text{Autoconsumo}}_{h,q} \\
 & \quad \Downarrow \\
 & \sum_{h=1}^{24} \widehat{\text{Autoconsumo}}_{h,d} \quad (\text{autoconsumo diario}) \\
 & \quad \Downarrow \\
 & \sum_d \sum_{h=1}^{24} \widehat{\text{Autoconsumo}}_{h,d} \quad (\text{trimestre / año})
 \end{aligned}$$

El autoconsumo estimado puede definirse de la siguiente manera:

$$\text{Autoconsumo}_{h,q,d} = \delta_{h,q} \cdot \text{zrad}_d + w_{h,q}$$

Donde:

- $\text{Autoconsumo}_{h,q,d}$ representa la variación logarítmica de la demanda eléctrica para la hora h del trimestre q , en su día d , utilizada como una aproximación del autoconsumo solar (en MWh).
- $\text{zrad}_{d,q}$ es la radiación solar normalizada correspondiente al día d del trimestre q .
- $\delta_{h,q}$ es el coeficiente estimado de la variable zrad para la hora h y el trimestre q , obtenido a partir del modelo Reg-ARIMA.
- $w_{h,q}$ es el término de error aleatorio.

Ejecutando varias líneas de comando (ver Anexo) se puede crear una matriz en la que, teniendo un coeficiente para cada hora y en cada trimestres y teniendo la radiación estandarizada para cada día, se obtiene la matriz $\text{Autoconsumo}_{h,d}$, la cual tiene dimensiones 1611 x 24 (es decir los 1611 días que hay desde el 1 de enero de 2021 hasta el 30 de mayo de 2025, y las 24 horas).

4. MODELIZACIÓN Y ESTIMACIÓN

	h1	h2	h3	h4	h5	h6	h7	h8	h9	h10	h11	h12	h13	h14	h15	h16	h17	h18
1	0.004855059	0.0034161292	0.0022689489	0.0022300174	0.0022024160	0.0013700997	0.0026485084	0.0009989900	-0.0017020071	-0.005388333	-0.009212456	-0.010460332	-0.013088110	-0.015821931	-0.015195235	-0.013714385	-0.012042046	
2	0.005680014	0.0039989255	0.0026544806	0.0026089340	0.0025766427	0.0016029022	0.0030985335	0.0011687348	-0.0019912061	-0.006303900	-0.010777804	-0.012261113	-0.015311994	-0.018510337	-0.017777155	-0.016044685	-0.014088187	
3	0.006153348	0.0043321693	0.0028756873	0.00280263452	0.0027913629	0.0017364773	0.0033567446	0.0012661293	-0.0021571399	-0.006829225	-0.011675954	-0.013282872	-0.016587994	-0.020052865	-0.019258585	-0.017381742	-0.015262203	
4	0.004855059	0.0034161292	0.0022689489	0.0022300174	0.0022024160	0.0013700997	0.0026485084	0.0009989900	-0.0017020071	-0.005388333	-0.009212456	-0.010460332	-0.013088110	-0.015821931	-0.015195235	-0.013714385	-0.012042046	
5	0.006126300	0.0043131268	0.0028630470	0.0028139217	0.0027790932	0.0017288445	0.0033419897	0.0012605639	-0.0021476580	-0.006799206	-0.011624631	-0.013224466	-0.016515080	-0.019964720	-0.019173932	-0.017305339	-0.015195116	
6	0.005571823	0.0039027555	0.0026039191	0.0025592401	0.0025275638	0.0015723707	0.0030395138	0.0011464732	-0.0019532783	-0.006183826	-0.010572512	-0.012027568	-0.015020337	-0.018157759	-0.017438543	-0.015739072	-0.013819841	
7	0.002123243	0.0014948365	0.0009922701	0.0009752444	0.0009631736	0.0005991801	0.0011582613	0.0004368842	-0.0007443318	-0.002356458	-0.004028846	-0.004583321	-0.005723769	-0.006919340	-0.006645270	-0.005997656	-0.005266299	
8	0.001566766	0.0011044652	0.0007331423	0.0007205627	0.0007116442	0.0004427063	0.0008557854	0.0003227934	-0.0005495522	-0.001741077	-0.002976727	-0.003386403	-0.004229027	-0.005112379	-0.004909861	-0.004431389	-0.003891023	
9	0.001136003	0.0007997851	0.0005308961	0.0005217868	0.0005153285	0.0003205804	0.0006197067	0.0002337470	-0.0003982412	-0.001260780	-0.002155561	-0.002452223	-0.003062399	-0.003702067	-0.003555431	-0.003208937	-0.002817637	
10	0.003894866	0.0027421204	0.0018202153	0.0017888633	0.0017668407	0.0010991329	0.0021247087	0.0008014181	-0.0013653984	-0.004322674	-0.007390494	-0.008407620	-0.010499653	-0.012692802	-0.012190049	-0.011002070	-0.009660471	
11	0.006599835	0.0046463706	0.0030842537	0.0030313329	0.0029938134	0.0018624197	0.0036002008	0.0013579585	-0.0023135918	-0.007324531	-0.012522781	-0.014246245	-0.017791079	-0.021507248	-0.020655362	-0.018642396	-0.016369132	
12	0.009060210	0.0056746658	0.0037668344	0.0037022016	0.0036563787	0.0022745945	0.0043969666	0.0016584903	-0.0028256162	-0.008945534	-0.015294216	-0.017399103	-0.021728449	-0.026267049	-0.025226630	-0.022768172	-0.019991809	
13	0.007749161	0.0054556770	0.0036214700	0.0035599314	0.0035152768	0.0021868165	0.0042272850	0.0015944882	-0.0027165740	-0.008600321	-0.014704003	-0.016727661	-0.020889935	-0.025253388	-0.024253119	-0.021889534	-0.019220313	
14	0.007316398	0.0051509970	0.0034192238	0.0033605555	0.0033189612	0.0020646906	0.0039912063	0.0015054417	-0.0025648631	-0.008120023	-0.013882837	-0.015793481	-0.019723307	-0.023843076	-0.022898669	-0.020667082	-0.018146927	
15	0.007316398	0.0051509970	0.0034192238	0.0033605555	0.0033189612	0.0020646906	0.0039912063	0.0015054417	-0.0025648631	-0.008120023	-0.013882837	-0.015793481	-0.019723307	-0.023843076	-0.022898669	-0.020667082	-0.018146927	
16	0.006181924	0.0057603570	0.0036237161	0.00357581074	0.0035711925	0.0023089424	0.0044633637	0.0016835346	-0.0028682849	-0.009080618	-0.015525169	-0.017661841	-0.022056563	-0.026663699	-0.025607569	-0.023111987	-0.020293698	
17	0.007722114	0.0054366345	0.0036088296	0.0035469079	0.0035030071	0.0021791837	0.0042125301	0.0015889228	-0.0027070921	-0.008570302	-0.014652681	-0.016669275	-0.020817021	-0.025165243	-0.024168466	-0.021813131	-0.019153226	
18	0.008317163	0.0058555696	0.0038869181	0.0038202248	0.0037729411	0.0023471067	0.0045371383	0.0017113616	-0.0029156946	-0.009230710	-0.015781784	-0.017953772	-0.022421135	-0.027104421	-0.026030835	-0.023494003	-0.020629131	
19	0.007654494	0.0053890282	0.0035772286	0.0035158492	0.0034723328	0.0021601015	0.0041756428	0.0015750092	-0.0026833872	-0.008495256	-0.014534373	-0.016523309	-0.020634735	-0.024944882	-0.023956833	-0.021622123	-0.018985510	
20	0.001717528	0.0012091989	0.0008026644	0.0007888920	0.0007791277	0.0004946871	0.0009369375	0.0003534031	-0.0006021028	-0.001906179	-0.003259003	-0.003707527	-0.004630055	-0.005597173	-0.005375473	-0.004851607	-0.004260000	
21	0.003326865	0.0023422278	0.0015547672	0.0015280899	0.0015091764	0.0009388427	0.0018148553	0.0006845447	-0.0011662778	-0.003692284	-0.006312714	-0.007181509	-0.008966454	-0.010841769	-0.010412334	-0.009397601	-0.008251653	
22	0.004787440	0.0033705230	0.0022373480	0.0021989587	0.0021717417	0.0013510175	0.0026116211	0.0009850765	-0.0016783023	-0.005313287	-0.009084149	-0.010334367	-0.012905824	-0.015601569	-0.014983602	-0.013523377	-0.011874329	
23	0.002042100	0.0014377089	0.0009543490	0.0009379739	0.0009263644	0.0005762815	0.0011139966	0.0004020180	-0.0007158860	-0.002266402	-0.003874877	-0.004408162	-0.005505027	-0.006654907	-0.006391311	-0.005768446	-0.005065039	

Figura 4.23: Matriz Autoconsumo $_{h,q,d}$ de coeficientes estimados por hora. Cada columna representa una hora del día y cada fila un día, mostrando la variación del efecto de la radiación solar a lo largo del tiempo.

Ahora bien esta matriz no representa la cantidad de energía producida por el autoconsumo, sino una magnitud micro y estructural, dado, como se ha explicado antes, por:

$$\text{Autoconsumo}_{h,q,d} = \delta_{h,q(d)} \cdot \text{zrad}_d$$

Esta magnitud es adimensional y representa un efecto relativo del autoconsumo, es decir, la intensidad con la que la radiación reduce la demanda observada, independientemente del nivel absoluto de consumo.

4.3.4. Interpretación del efecto de la radiación y construcción energética del autoconsumo

Los modelos horarios estimados en este trabajo se formulan sobre la demanda eléctrica transformada logarítmicamente, como se indicó en el apartado anterior, por eso, el coeficiente asociado a la radiación solar estandarizada lo que hace es capturar el efecto marginal de dicha variable sobre la demanda observada, de modo que la relación estimada puede expresarse de forma genérica como:

$$\log(\text{Demanda}_{d,h}) = \delta_{h,q(d)} \cdot \text{zrad}_d + \dots$$

Si se deshace la transformación logarítmica, la relación entre la demanda y la radiación adopta una forma exponencial.

$$\text{Demanda}_{d,h} = \exp(\delta_{h,q(d)} \cdot \text{zrad}_d)$$

Dado que los coeficientes estimados son en su mayoría negativos, como ya se mencionó anteriormente, un aumento de la radiación solar se traduce en una reducción proporcional de la demanda (lo cual se puede interpretar como un efecto provocado por el autoconsumo eléctrico), este efecto desde un punto de vista teórico podría expresarse como:

$$1 - \exp(\delta_{h,q(d)} \cdot \text{zrad}_d)$$

No obstante, en la práctica, los valores de $\delta_{h,q(d)} \cdot \text{zrad}_d$ son de pequeña magnitud, como se puede ver en la Figura 4.23. En este rango, la función exponencial puede aproximarse mediante una expansión de primer orden, de forma que:

$$\exp(x) \approx 1 + x, \quad \text{solo para valores pequeños de } x$$

que operando es:

$$1 - \exp(x) \approx -x$$

Por tanto, lo que podría haber sido:

$$\text{Autoconsumo}_{d,h}^{(E)} = S_{d,h} \cdot \text{Autoconsumo}_{d,h} = S_{d,h} \cdot (1 - \exp(\delta_{h,q(d)} \cdot \text{zrad}_d))$$

Gracias a ser números pequeños, mediante esta aproximación matemática, se puede modelizar el efecto del autoconsumo de manera lineal a través de la siguiente expresión:

$$\text{Autoconsumo}_{d,h}^{(E)} = S_{d,h} \cdot \text{Autoconsumo}_{d,h} = -S_{d,h} \cdot \delta_{h,q(d)} \cdot \text{zrad}_d$$

donde $S_{d,h}$ es la demanda eléctrica observada en MWh, y $\text{Autoconsumo}_{d,h}$ no es otra cosa más que la matriz que se construyó en el apartado anterior, a la cual no hace falta aplicarle una exponencial, solo premultiplicarla por los correspondientes consumos observados para esos días y horas, los cuales están en la base de datos inicial de la que se inició este Trabajo de Fin de Grado.

Graficando las estimaciones en diferentes medidas temporales (días, meses, trimestres). Se puede apreciar lo siguiente:




Figura 4.24: Autoconsumo estimado horario en el sistema eléctrico peninsular (2021–2025).




Figura 4.25: Autoconsumo mensual estimado en el sistema eléctrico peninsular (2021–2025).

Atendiendo a las gráficas de las Figura 4.24 y Figura 4.25 se verifica, como así es el objetivo de este apartado, que los resultados obtenidos son coherentes y consistentes, ya que se puede observar que:

- En los meses de invierno de todos los años el autoconsumo estimado, a partir de los coeficientes del modelo, es notablemente menor que en los meses de verano.
- Se respalda así el desarrollo y resultado realizado en los apartados anteriores.
- El autoconsumo a lo largo de los años va aumentando.
- Todos los picos de autoconsumo se obtienen en los meses de junio, lo cual tiene sentido ya que este mes es el que más horas de luz tiene.
- Existe una clara estacionalidad en el autoconsumo estimado.

Si comparamos los resultados que se han obtenido del análisis y comprobación del regresor y sus coeficientes con las diferentes fuentes de información en las que se explica el incremento del autoconsumo, se puede ver que lo realizado en este Trabajo de Fin Grado es coherente y arroja una base estadística y matemática explicativa sólida con la realidad.




Figura 4.26: Evolución del autoconsumo eléctrico en España y comparación con los objetivos marcados por la Agenda 2030. Fuente: Newtral, reproducido de [19].

Como se muestra en la imagen superior es notorio el auge del autoconsumo eléctrico en España durante los últimos cuatro años siendo el 2025 el año en el que se sobrepasó incluso el objetivo marcado por la Agenda 2030 para España.




Figura 4.27: Evolución y crecimiento interanual de la potencia de autoconsumo fotovoltaico instalada en España. Fuente: C de Comunicación, reproducido de [20].

En esta otra noticia (Figura 4.27), se puede destacar el crecimiento interanual del autoconsumo, con un particular despegue iniciado en el año 2021 y consolidado en el año 2022.




Figura 4.28: Autoconsumo trimestral estimado en el sistema eléctrico peninsular (2021–2025).

En la Figura 4.28 se agrupa el autoconsumo estimado de manera que se pueda observar por trimestres, como es de esperar en los trimestres fríos el autoconsumo es menor que en los cálidos. Nótese que el último trimestre analizado no está completo ya que es hasta el día 30 de mayo de 2025.




Figura 4.29: Porcentaje de autoconsumo mensual respecto al total de la demanda eléctrica del sistema peninsular (2021–2025).

- Se puede ver una tendencia que crece de forma sostenida a lo largo de los últimos años, esto soporta la idea de que cada vez es mayor la contribución del autoconsumo con respecto al total de la demanda.
- A partir del 2023 se observa una aceleración del crecimiento, alcanzándose a finales de mayo de 2025 porcentajes que rondan el 10 %
- Estos resultados son un reflejo de la importante consolidación del autoconsumo como pilar estructural en el sistema eléctrico.
- El aumento del porcentaje de autoconsumo es consistente con la expansión de la potencia fotovoltaica instalada (como se ha visto en páginas anteriores).

5. CONCLUSIONES Y POSIBLES LÍNEAS FUTURAS

5.1. Conclusiones

En el presente Trabajo de Fin de Grado se ha analizado y modelizado la demanda eléctrica peninsular española, prestando atención en concreto al efecto de la radiación solar y su impacto, a través del autoconsumo fotovoltaico, en los patrones tradicionales de consumo.

Para ello se ha desarrollado una metodología basada en modelos ARIMA horarios, en los que progresivamente se han ido incorporando variables explicativas relevantes como festividades, temperatura y finalmente la radiación solar.

Se ha comprobado a lo largo de los diferentes apartados de modelización y estimación del modelo que los modelos ARIMA horarios constituyen una herramienta adecuada para la predicción a corto plazo de la demanda eléctrica, ya que son capaces de capturar con poco error, la tendencia y la estacionalidad característica del sistema eléctrico peninsular.

La inclusión de variables explicativas ha permitido ir mejorando progresivamente el desempeño del modelo, en el caso de las festividades, se ha concluido que existe una clara diferenciación entre días laborables, fines de semana y festivos, esto ha permitido reducir de manera apreciable el error del modelo.

Del mismo modo, la temperatura ha mostrado tener un efecto significativo en la demanda, con una relación de tipo cuadrático que refleja el aumento de dicha demanda en situaciones de frío o calor extremos, asociado al uso del sistema de calefacción y climatización a lo largo del año.

Finalmente, uno de los principales resultados del trabajo es constatación y análisis de la radiación solar, incorporándose como regresor adicional y mejorando la capacidad explicativa del modelo durante las horas centrales del día.

Este efecto se ha manifestado como una reducción sistemática de la demanda observada respecto a la predicha por el modelo base, coherente con un creciente uso del autoconsumo fotovoltaico en las horas con mayor irradiación solar. A partir de los coeficientes estimados asociados a la radiación se ha realizado una estimación del autoconsumo (a escala horaria, mensual y trimestral) y los resultados obtenidos muestran un crecimiento significativo en los últimos 5 años.

Aunque estas estimaciones no son sustitutivas de otros datos oficiales, sí aportan una aproximación coherente y consistente al orden de magnitud del fenómeno, reforzando la idea de que el autoconsumo constituye ya un elemento muy relevante de cara a planificar el sistema eléctrico.

5.2. Limitaciones y líneas futuras

Existen ciertas limitaciones en este análisis, ya que no se cuenta con fuentes ni datos oficiales que puedan respaldar de forma directa la potencia instalada en España.

Este estudio se ha realizado además a nivel peninsular como una sola región, no se ha tenido en cuenta, los territorios insulares ni la idea de que la radiación afecta de manera diferente entre regiones dentro de la propia península.

Finalmente RStudio, aunque es una herramienta muy potente, en los últimos pasos, en los que para cada hora tenía que estimar los coeficiente para los 18 trimestres además del resto

de coeficientes asociadas a las festividades y temperatura, empezaba a procesar de manera notablemente más lenta, si este modelo se pretendiese escalar posiblemente este factor sería limitante.

Por tanto, de cara al futuro y el desarrollo de líneas futuras, sería de especial interés

- Disponer de datos más completos y precisos sobre el autoconsumo (tanto en potencia instalada como de generación efectiva).
- División de la península en diferentes regiones geográficas.
- Uso de herramientas con mayor escalabilidad como pueden ser Matlab o Python.

6. PLANIFICACIÓN Y PRESUPUESTO

6.1. Plantilla de EDP

Se realiza la EDP (Estructura de Descomposición del Proyecto), ya que se considera una herramienta fundamental para visualizar de forma clara el alcance del trabajo, las fases que lo han compuesto y los diferentes bloques.

En la siguiente figura se puede visualizar la descomposición del proyecto global en tareas y sub-tareas jerarquizadas.




Figura 6.1: Estructura de Descomposición del Proyecto (EDP) del trabajo.

6.2. Presupuesto

El presupuesto estimado para la íntegra realización de este Trabajo de Fin de Grado se ha elaborado considerando sobretodo los recursos humanos y técnicos para el desarrollo del mismo.

Se ha tenido en cuenta el tiempo dedicado por el alumno a las tareas de análisis de datos, programación en RStudio y redacción del documento, además del tiempo invertido por el tutor para su seguimiento.

El trabajo se ha realizado usando un equipo informático personal y herramientas de software de uso académico y gratuito como R, Excel y TexStudio, sin que haya sido necesario incurrir en costes adicionales para otro tipo de licencias. Es importante resaltar que las bases de datos usadas son públicas y de libre acceso.

Se aglutina toda esta información en la siguiente tabla:

Tabla 6.1: Estimación del presupuesto asociado a la realización del Trabajo de Fin de Grado

Concepto	Detalle	Coste estimado
Tiempo del estudiante	A una media de 30 horas por ECTS y a 10 euros/hora	3600 euros
Tiempo del tutor	20 horas a 40 euros/hora	800 euros
Software	RStudio, paquete Office, TeXstudio	0 euros
Amortización de equipos informáticos y luz	Uso de ordenador, costes operativos, conexión, etc.	50 euros
TOTAL ESTIMADO		4450 euros

6.3. Diagrama de Gantt

Partiendo de la base organizativa que aporta la EDP, se construye el Diagrama de Gantt del proyecto, con la característica explícita de que se incluye la dimensión temporal, es decir, permite analizar cuándo se ejecuta cada tarea así como cuál es su duración y su posible solapamiento con otras tareas.

A continuación se muestra el Diagrama de Gantt correspondiente a este proyecto.




Figura 6.2: Diagrama de Gantt del Trabajo de Fin de Grado (febrero 2025 – enero 2026).

7. CÓDIGO

7.1. Lectura de datos y primeros pasos

```

1      # Carga de librerías necesarias para el análisis
2
3      library(forecast)      # Para poder modelizar las series temporales
4      library(dygraphs)     # para poder visualizar los paquete
5      library(lubridate)    # Manipulación y gestión de fechas
6      library(xts)          # Construcción de series temporales
7      library(htmlwidgets)  # Exportación de gráficos interactivos
8      library(ggplot2)      # Gráficos estáticos de alta calidad
9      library(scales)       # Formateo de ejes y escalas en gráficos
10
11
12
13      datos = read.table("demanda_PENIN.txt", sep = ";", header =
↪ FALSE, skip = 1)
14      #se importan los datos desde un archivo de texto , además se
↪ omite la primera fila ya que no era cabecera y para operar
15      cogía mal los datos de consumo.
16      colnames(datos)=c(
17          "fecha",
18          "demhora1","demhora2","demhora3","demhora4","demhora5","demhora6",
19
↪ "demhora7","demhora8","demhora9","demhora10","demhora11","demhora12",
20
↪ "demhora13","demhora14","demhora15","demhora16","demhora17","demhora18",
21
↪ "demhora19","demhora20","demhora21","demhora22","demhora23","demhora24"
22      )
23      #se asignanan el nombre a las columnas
24      f =ymd(datos$fecha)
25      #se convierten las fechas en formato adecuado para poder tratar
↪ mejor con ellas
26      demhora12 = xts(datos$demhora12, f)
27      #se crea la primera serie temporal para la hora 12
28      dygraph(demhora12, main = "Demanda en MWh a las 12")
29      #se grafica como ejemplo
30      dyRangeSelector(
31      dygraph(demhora12, main = "Demanda en MWh durante 1 semana"))
32      #gráfico interactivo
33
34      print((datos[datos$fecha == 20190124, ]))
35      print((datos[datos$fecha == 20190424, ]))
36      print((datos[datos$fecha == 20190724, ]))
37      print((datos[datos$fecha == 20191024, ]))
38
39      #se imprime la demanda por pantalla para esas fechas
40
41
42

```

Código 7.1: Carga de librerías y primeras comprobaciones.

7.2. Cambios de hora

```

43 demhora2 = xts(datos$demhora2, f)
44 dygraph(demhora2, main = "Demanda en MWh a las 2 de la mañana")
45
46 demhora3 = xts(datos$demhora3, f)
47 dygraph(demhora3, main = "Demanda en MWh a las 3 de la mañana")
48 #cambios de hora (esto se ejecuta solo una vez)
49 #corrección hora 2
50 #filtramos en la base de datos y vemos que las fechas problemáticas son:
↪ 25 de octubre de 2015, 30 de octubre de 2016, 29 de octubre de 2017 y 28
↪ de octubre de 2018
51 datos[datos$fecha == 20151025, "demhora2"] = datos[datos$fecha == 20151025
↪ , "demhora2"] / 2
52 datos[datos$fecha == 20161030, "demhora2"] = datos[datos$fecha == 20161030
↪ , "demhora2"] / 2
53 datos[datos$fecha == 20171029, "demhora2"] = datos[datos$fecha == 20171029
↪ , "demhora2"] / 2
54 datos[datos$fecha == 20181028, "demhora2"] = datos[datos$fecha == 20181028
↪ , "demhora2"] / 2
55 #corrección hora 3
56 #para las siguientes fechas: 30 de octubre de 2011, 28 de octubre de 2012,
↪ 27 de octubre de 2013 ;dividimos entre dos
57 datos[datos$fecha == 20121028, "demhora3"] = datos[datos$fecha == 20121028
↪ , "demhora3"] / 2
58 datos[datos$fecha == 20131027, "demhora3"] = datos[datos$fecha == 20131027
↪ , "demhora3"] / 2
59 datos[datos$fecha == 20111030, "demhora3"] = datos[datos$fecha == 20111030
↪ , "demhora3"] / 2
60
61 #en estas fechas, por el cambio de hora a las 3 de la mañana(hora 3), el
↪ valor es
62 datos[datos$fecha == 20110327, "demhora3"] =
63 (datos[datos$fecha == 20110327, "demhora2"] +
64 datos[datos$fecha == 20110327, "demhora4"]) / 2
65
66 datos[datos$fecha == 20120325, "demhora3"] =
67 (datos[datos$fecha == 20120325, "demhora2"] +
68 datos[datos$fecha == 20120325, "demhora4"]) / 2
69
70 datos[datos$fecha == 20130331, "demhora3"] =
71 (datos[datos$fecha == 20130331, "demhora2"] +
72 datos[datos$fecha == 20130331, "demhora4"]) / 2
73
74 datos[datos$fecha == 20140330, "demhora3"] =
75 (datos[datos$fecha == 20140330, "demhora2"] +
76 datos[datos$fecha == 20140330, "demhora4"]) / 2
77
78 datos[datos$fecha == 20150329, "demhora3"] =
79 (datos[datos$fecha == 20150329, "demhora2"] +
80 datos[datos$fecha == 20150329, "demhora4"]) / 2
81
82 datos[datos$fecha == 20160327, "demhora3"] =
83 (datos[datos$fecha == 20160327, "demhora2"] +
84 datos[datos$fecha == 20160327, "demhora4"]) / 2
85
86

```

Código 7.2: Corrección de las series horarias de demanda eléctrica asociadas a los cambios de hora oficiales (horario de verano e invierno).

```
87     datos[datos$fecha == 20170326, "demhora3"] =
88     (datos[datos$fecha == 20170326, "demhora2"] +
89     datos[datos$fecha == 20170326, "demhora4"]) / 2
90     datos[datos$fecha == 20180325, "demhora3"] =
91     (datos[datos$fecha == 20180325, "demhora2"] +
92     datos[datos$fecha == 20180325, "demhora4"]) / 2
93
94     #por si quieres visualizar otra vez que no hay errores
95     demhora2= xts(datos$demhora2, f)
96     dygraph(demhora2, main= "Demanda en MWh a las 2 de la mañana CORREGIDA")
97
98     demhora3= xts(datos$demhora3, f)
99     dygraph(demhora3, main= "Demanda en MWh a las 3 de la mañana CORREGIDA")
100
101     #representación de la hora 10 , la hora más difícil
102     demhora10= xts(datos$demhora10, f)
103     dygraph(demhora10, main="Demanda en MWh a las 10 de la mañana")
104
```

Código 7.3: Corrección de las series horarias de demanda eléctrica asociadas a los cambios de hora oficiales (horario de verano e invierno).

7.3. Creación del modelo

```
105  tsdisplay(demhora10) #representamos gráficamente
106
107  y10 = log(demhora10) #le aplicamos logaritmo
108
109  plot(y10,main = "Evolución de la demanda eléctrica a las 10:00",sub =
110  ↪ "Serie transformada mediante logaritmo natural",
111  xlab = "Año",ylab = "log(Demanda eléctrica en MWh)",col = "blue",lwd = 0.2)
112  ↪ #con el plot se dibuja la nueva gráfica
113
114  u = diff(y10) #se aplica la primera diferenciación para estabilizar la media
115
116  plot(diff(y10),
117  main = "Primera diferencia de la demanda eléctrica (10:00)",
118  xlab = "Fecha",ylab = " log(Demanda)",col = "olivedrab3",lwd = 0.1) #con el
119  ↪ plot se dibuja este cabio
120
121  abline(h = 0, col = "red", lwd = 2) #esto es simplemente para poderlo
122  ↪ representar gráficamente de forma más llamativa
```

Código 7.4: Transformación logarítmica y diferenciación de la serie horaria de demanda eléctrica a las 10:00.

```
120  acf(diff(y10), 50, na.action = na.pass) #para poder ver la función de
121  ↪ autocorrelación simple
122
123  pacf(diff(y10), 50, na.action = na.pass) #para poder ver la función de
124  ↪ autocorrelación parcial
125
126  #además na.action=na.pass sirve para que ignore, si los hubiera, valores NA
```

Código 7.5: Funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) de la serie diferenciada de demanda eléctrica a las 10:00.

```
126  y10seasonal = diff(u, 7) #aquí diferenciamos semanalmente
127  plot(y10seasonal) #se dibuja esta nueva diferenciación
128
129  #se revuelve a representar las acf y pacf (además se grafican solo 50 lags)
130  acf(y10seasonal, 50, na.action = na.pass)
131  pacf(y10seasonal, 50, na.action = na.pass)
```

Código 7.6: Corrección de la estacionalidad semanal y análisis ACF y PACF de la serie transformada.

```

133   #se crean diferentes modelos arima en función de lo que se ha visto en las
134   ↪ gráficas acf y pacf
135   m10_1 = arima(log(demhora10), order = c(0,1,1),
136   seasonal = list(order = c(0,1,1), period = 7))
137   summary(m10_1)
138
139   m10_2 = arima(log(demhora10), order = c(0,1,1),
140   seasonal = list(order = c(0,1,2), period = 7))
141   summary(m10_2)
142
143   m10_3 = arima(log(demhora10), order = c(0,1,2),
144   seasonal = list(order = c(0,1,1), period = 7))
145   summary(m10_3)
146
147   m10_4 = arima(log(demhora10), order = c(0,1,2),
148   seasonal = list(order = c(0,1,2), period = 7))
149
150   #nótese el componente estacional en los diferentes modelos
151   summary(m10_4) #ahora con summary se ven los diferentes parámetros
152
153   summary(m10_3) #m10_3 es el modelo más polivalente
154   checkresiduals(m10_3) #se chequean los residuos
155
156   #con los parámetros escogidos, se genera un bucle para poder realizar el
157   ↪ modelo para las 24 horas, es decir , se crean 24 modelos
158   for (h in 1:24) {
159       col <- paste0("demhora", h)          # Nombre de la columna
160       bh <- xts(datos[[col]], f)           # Serie temporal con fechas f
161       mbh <- arima(log(bh),                # Modelo ARIMA con log transformado
162       order = c(0,1,2),
163       seasonal = list(order = c(0,1,1), period = 7))
164       cat("\n--- Hora", h, "---\n")
165       print(summary(mbh))}

```

Código 7.7: Estimación y comparación de distintas especificaciones ARIMA estacionales para la demanda eléctrica a las 10:00.

7.4. Regresor festivos

```

165 #Empezamos por leer la base de datos que contiene todos los regresores
166 x_fes = read.table("regresores_penin.txt",header=TRUE,sep=";")
167
168 #creamos nueva matriz y añadimos las columnas que nos interesan
169 matriz_festivos = x_fes[, c( "fest_nac_06EN" ,
↪ "fest_nac_01MY","fest_nac_15AG", "fest_nac_12OC" ,
↪ "fest_nac_01NO" , "fest_nac_06DI", "fest_nac_24DI" ,
↪ "fest_nac_31DI")]
170 head(matriz_festivos) #verificamos la estructura
171
172 # Creamos otro festivo: 25 de diciembre (Navidad)
173 x_fes$fest_nac_25DI <- 0 # columna nueva con ceros
174
175 # Ponemos 1 en las fechas que son 25 de diciembre
176 x_fes$fest_nac_25DI[x_fes$mes == 12 & x_fes$dia == 25] = 1
177 # Añadimos las nuevas columnas a la matriz de festivos
178 matriz_festivos$fest_nac_25DI <- x_fes$fest_nac_25DI
179
180 #Creamos otro festivo: 1 de enero año nuevo
181 x_fes$fest_nac_01EN=0
182 x_fes$fest_nac_01EN[x_fes$mes == 1 & x_fes$dia == 1] = 1
183 matriz_festivos$fest_nac_01EN = x_fes$fest_nac_01EN
184 #Creamos otro festivo: 8 de diciembre (Inmaculada)
185 x_fes$fest_nac_08DI=0
186 x_fes$fest_nac_08DI[x_fes$mes == 12 & x_fes$dia == 8] = 1
187 matriz_festivos$fest_nac_08DI = x_fes$fest_nac_08DI
188 #Creamos otro festivo: Viernes Santo
189 x_fes$fest_nac_VS=0
190 x_fes$fest_nac_VS[x_fes$mes == 4 & x_fes$dia == 22 & x_fes$ano== 2011] = 1
191 x_fes$fest_nac_VS[x_fes$mes == 4 & x_fes$dia == 6 & x_fes$ano== 2012] = 1
192 x_fes$fest_nac_VS[x_fes$mes == 3 & x_fes$dia == 29 & x_fes$ano== 2013] = 1
193 x_fes$fest_nac_VS[x_fes$mes == 4 & x_fes$dia == 18 & x_fes$ano== 2014] = 1
194 x_fes$fest_nac_VS[x_fes$mes == 4 & x_fes$dia == 3 & x_fes$ano== 2015] = 1
195 x_fes$fest_nac_VS[x_fes$mes == 3 & x_fes$dia == 25 & x_fes$ano== 2016] = 1
196 x_fes$fest_nac_VS[x_fes$mes == 4 & x_fes$dia == 14 & x_fes$ano== 2017] = 1
197 x_fes$fest_nac_VS[x_fes$mes == 3 & x_fes$dia == 30 & x_fes$ano== 2018] = 1
198 x_fes$fest_nac_VS[x_fes$mes == 4 & x_fes$dia == 19 & x_fes$ano== 2019] = 1
199 x_fes$fest_nac_VS[x_fes$mes == 4 & x_fes$dia == 10 & x_fes$ano== 2020] = 1
200 x_fes$fest_nac_VS[x_fes$mes == 4 & x_fes$dia == 2 & x_fes$ano== 2021] = 1
201 x_fes$fest_nac_VS[x_fes$mes == 4 & x_fes$dia == 15 & x_fes$ano== 2022] = 1
202 x_fes$fest_nac_VS[x_fes$mes == 4 & x_fes$dia == 7 & x_fes$ano== 2023] = 1
203 x_fes$fest_nac_VS[x_fes$mes == 3 & x_fes$dia == 29 & x_fes$ano== 2024] = 1
204 x_fes$fest_nac_VS[x_fes$mes == 4 & x_fes$dia == 18 & x_fes$ano== 2025] = 1
205 matriz_festivos$fest_nac_VS = x_fes$fest_nac_VS
206
207 # Para finalizar el apartado de festivos regionales como regresorss
208 # Paso 1: copiar la columna fest_regionales
209 matriz_festivos$fest_regionales = x_fes$fest_regionales
210 # Paso 2: reemplazar todos los 1 por 0 en fest_regionales
211 matriz_festivos$fest_regionales[matriz_festivos$fest_regionales == 1] = 0
212
213 #Finalmente se añade este regresor al modelo usando la función xreg y con
↪ el summary se empieza a verificar si se ha mejorado el modelo
214 m10_3_festivos= arima( log(demhora10), order = c(0,1,2), seasonal=
↪ list(order=c(0,1,1), period=7),xreg = matriz_festivos)
215 summary(m10_3_festivosDEF)
216

```

Código 7.8: Creación de festividades e inclusión de las variables festivas como regresores en modelos ARIMA de demanda eléctrica.

7.5. Regresor temperatura

```

217 #Leer datos de su base de datos correspondiente
218 x_tem = read.table("meteorologia_penin.txt",header=TRUE,sep=";")
219
220 #Ahora se estandarizan las diferentes variables
221 zmin = (x_tem$tmin- min(x_tem$tmin))/(max(x_tem$tmin)- min(x_tem$tmin))
222 zmax = (x_tem$tmax- min(x_tem$tmax))/(max(x_tem$tmax)- min(x_tem$tmax))
223 zmin2 = zmin^2
224 zmax2 = zmax^2
225
226 #Se dibuja
227 plot(x_tem$tmax, datos$demhora10, xlab="Temperatura(°C)", ylab= "Demanda en
↪ MWh hora 10")
228
229 #Se observan diferentes nubes, por eso vamos a diferenciar los días de la
↪ semana respecto de sabados y domingos
230 w= weekdays(ymd(x_tem$fecha))
231 sabado= (w== "sábado")
232 domingo= (w== "domingo")
233 plot(x_tem$tmax, datos$demhora10, xlab="Temperatura(°C)", ylab= "Demanda en
↪ MWh hora 10") #se vuelve a dibujar
234 points( x_tem$tmax[sabado],datos$demhora10[sabado], col="green") #para
↪ marcar los colores
235 points( x_tem$tmax[domingo],datos$demhora10[domingo], col="blue") #points
↪ sirve para que dentro del plot poder poner de color diferente los sabado
↪ y los domingos
236
237 #Lo metemos todo en la matriz
238 matriz_festytem = cbind(matriz_festivos, zmax, zmin, zmax2, zmin2) #cbind
↪ sirve para juntarlo todo en la matriz
239
240 #Modelo arima con temperaturas y festivos
241 m10_3_festytem= arima( log(demhora10), order = c(0,1,2), seasonal=
↪ list(order=c(0,1,1), period=7),xreg = matriz_festytem)
242 summary(m10_3_festytem)
243
244 #Se genera el bucle para los 24 modelos
245
246 for (h in 1:24) {
247   col <- paste0("demhora", h) # Nombre de la columna
248   bh <- xts(datos[[col]], f) # Serie temporal con fechas f
249   mbh <- arima(log(bh), # Modelo ARIMA con log transformado
250     order = c(0,1,2),
251     seasonal = list(order = c(0,1,1), period = 7),xreg= matriz_festytem)
252   cat("\n--- Hora", h, "---\n") #para imprimir por pantalla en un formato
↪ amigable
253   print(summary(mbh))
254 }
255

```

Código 7.9: Inclusión de la temperatura y variables festivas como regresores en modelos ARIMA de demanda eléctrica.

7.6. Regresor radiación

```

256 #Misma base de datos, x_tem
257 #plot(x_tem$rad_PENIN, datos$demhora16, xlab="Radiación Solar", ylab=
↪ "Demanda en MWh hora 10")
258
259 zrad = (x_tem$rad_PENIN - min(x_tem$rad_PENIN)) / (max(x_tem$rad_PENIN) -
↪ min(x_tem$rad_PENIN))
260
261 zrad2 = zrad^2 #para el término cuadrático
262
263 #grafica interesante
264 w = weekdays(ymd(x_tem$fecha)) #identificación del día de la semana
265
266 #Clasificación de los días
267 laborable = !(w %in% c("sábado", "domingo"))
268 sabado = w == "sábado"
269 domingo = w == "domingo"
270 plot(x_tem$rad_PENIN[laborable],
271 datos$demhora10[laborable], xlab = "Radiación Solar", ylab = "Demanda en
↪ MWh (hora 10)", pch = 16, col = "grey")
272 points(x_tem$rad_PENIN[sabado],
273 datos$demhora10[sabado], col = "green", pch = 16) #pch es para
↪ representar mediante un punto sólido
274
275 points(x_tem$rad_PENIN[domingo], datos$demhora10[domingo],
276 col = "blue", pch = 16)
277 legend("topright", legend = c("Laborables", "Sábados", "Domingos"),
278 col = c("grey", "green", "blue"), pch = 16, bty = "n") #bty es para
↪ controlar el tipo de marco
279 #Lo metemos todo en la matriz
280 matriz_festytemyrad = cbind(matriz_festytem, zrad, zrad2)
281
282 #Modelo arima con temperaturas y festivos
283 m10_3_festytemyrad = arima(log(demhora10), order = c(0,1,2), seasonal=
↪ list(order=c(0,1,1), period=7), xreg = matriz_festytemyrad)
284 summary(m10_3_festytemyrad)
285
286 #bucle para todos los modelos
287 for (h in 1:24) {
288 col <- paste0("demhora", h) # Nombre de la columna
289 bh <- xts(datos[[col]], f) # Serie temporal con fechas f
290 mbh <- arima(log(bh), # Modelo ARIMA con log transformado
291 order = c(0,1,2),
292 seasonal = list(order = c(0,1,1), period = 7), xreg = matriz_festytemyrad)
293 cat("\n--- Hora", h, "---\n")
294 print(summary(mbh))
295 }
296
297 #Para terminar, se pueden analizar los residuos como al principio con más
↪ detenimiento
298 checkresiduals(m10_3_festytemyrad)
299

```

Código 7.10: Inclusión de las variables festivas, temperatura y radiación como regresores en modelos ARIMA de demanda eléctrica.

7.6.1. Modelización horaria con regresor de radiación y efecto trimestral

```

300 #Conversión de la fecha a formate date
301 fecha = as.Date(as.character(datos$fecha), format = "%Y%m%d")
302 #paso 1: crear trimestre
303 trimestre = paste0(
304   lubridate::year(fecha), # Año de la observación
305   "T", # Separador temporal
306   lubridate::quarter(fecha)# Trimestre del año)
307 #paso 2 : convertirlo en factor
308 trimestre = factor(trimestre)
309 #Se crea una versión segura del trimestre para evitar que haya NA antes del
    ↪ 2021
310 trimestre_2021_safe = trimestre_2021
311 levels(trimestre_2021_safe)= c(levels(trimestre_2021_safe), "PRE2021") #con
    ↪ esto lo que se busca es añadir explícitamente una categoría previa a 2021
312 trimestre_2021_safe[is.na(trimestre_2021_safe)] = "PRE2021"
313 trimestre_2021_safe = factor(trimestre_2021_safe) #conversión final a factor
314
315 #Se construye la matriz de regresores radiación por trimestre
316 xreg_rad_trim2021_full= model.matrix(~ zrad:trimestre_2021_safe - 1)
317 # eliminar columnas PRE2021
318 xreg_rad_trim2021 <- xreg_rad_trim2021_full[
319   , !grepl("PRE2021", colnames(xreg_rad_trim2021_full))]
320
321 #Ahora se pretende eliminar los regresores de radiación originales para
    ↪ evitar duplicidades
322 matriz_base_sin_rad <- matriz_festytemyrad[
323   , !colnames(matriz_festytemyrad) %in% c("zrad", "zrad2")]
324 #Construcción del regresor total del modelo
325 xreg_total <- cbind(
326   matriz_base_sin_rad,
327   xreg_rad_trim2021)
328
329 #bucle para todos los modelos
330 for (h in 1:24) {
331   col <- paste0("demhora", h)           # Nombre de la columna
332   bh <- xts(datos[[col]], f)             # Serie temporal con fechas f
333   mbh <- arima(log(bh),                 # Modelo ARIMA con log transformado
334     order = c(0,1,2),
335     seasonal = list(order = c(0,1,1), period = 7), xreg= xreg_total)
336   cat("\n--- Hora", h, "---\n")
337   print(summary(mbh))
338 }
339
340

```

Código 7.11: Construcción del regresor de radiación solar con efectos trimestrales e inclusión en modelos ARIMA horarios de demanda eléctrica.

7.6.2. Autoconsumo horario a partir de los coeficientes estimados

Las siguientes líneas de código son de las más importantes ya que a través de ellas se selecciona el periodo de análisis, se asigna a cada día su trimestre correspondiente y se construye la matriz de autoconsumo horario

```

341
342   zrad_p= matriz_festytemyrad$zrad #se extrae la radiacion estandarizada de
    ↪ su matriz
343   fecha_all= as.Date(as.character(datos$fecha), format = "%Y%m%d") #aunque ya
    ↪ estuviese, se vuelve a convertir las fechas a formato Date
344   ini= as.Date("2021-01-01") #define la fecha inicial
345   idx_2021= which(fecha_all >= ini) #indices a partir de la fecha inicial
346   zrad_p= as.numeric(matriz_festytemyrad$zrad[idx_2021]) #esta es la
    ↪ radiación solar desde la fecha indicada
347   fecha_p= fecha_all[idx_2021] #estas son las fechas, que están alineadas
    ↪ con la radiación
348
349   tri_lab= paste0(year(fecha_p), "T", quarter(fecha_p)) #parte muy importante
    ↪ ya que aquí se crea la etiqueta por año y trimestre para cada día
350   #ahora se define el orden de los trimestres
351   niveles_tri= c(
352     paste0("2021T", 1:4),
353     paste0("2022T", 1:4),
354     paste0("2023T", 1:4),
355     paste0("2024T", 1:4),
356     paste0("2025T", 1:2)
357   )
358   tri= factor(tri_lab, levels = niveles_tri) #se convierte a factor
359   tri_idx= as.integer(tri) #los trimestres del 1 al 18
360
361   Tlen= length(zrad_p) #nº total de días
362
363   A_hour= matrix(NA, nrow = Tlen, ncol = 24) #crea la matriz
364   colnames(A_hour)= paste0("h", 1:24) #pone nombre a las columnas, que son
    ↪ las horas
365   #bucle sobre los días
366   for (t in 1:Tlen) {
367     A_hour[t, ] = Delta[, tri_idx[t]] * zrad_p[t]
368   }
369

```

Código 7.12: Construcción de la matriz de autoconsumo horario mediante la combinación de coeficientes trimestrales estimados y radiación solar diaria estandarizada.

Como paso previo a poder ejecutar este código se ha tenido que guardar previamente los modelos por hora para posteriormente crear la matriz Delta 24 x 18 en la cual se guarden los regresores de los 18 trimestres para cada una de las 24 horas.

Esto queda definido en las siguientes líneas de código.

```
370 #Se define un vector para guardar toda la información requerida
371 fits = vector("list", 24)
372 #Se inicializa un bucle igual que se ha hecho antes pero ahora para guardar
↪ la información en fits
373 for (h in 1:24) {
374
375     col= paste0("demhora", h)
376     bh=xts(datos[[col]], f)    # f = vector de fechas (el que se ha usado
↪ antes)
377
378     fits[[h]]= arima(
379         log(bh),
380         order = c(0,1,2),
381         seasonal = list(order = c(0,1,1), period = 7),
382         xreg = xreg_total
383     )
384 }
385 #Ahora se crea la matriz Delta
386 Delta= matrix(
387     NA,nrow = 24,ncol = length(niveles_tri),
388     dimnames = list(paste0("h", 1:24), niveles_tri) )
389 for (h in 1:24) {
390     cf <- coef(fits[[h]])
391     nm <- names(cf)
392     # quedarnos solo con coeficientes zrad:trimestre
393     keep <- grepl("^zrad:trimestre", nm)
394     cf_z <- cf[keep]
395     nm_z <- nm[keep]
396     # extraer "2021T1", "2021T2", etc.
397     tri_name <- sub(".*(20[0-9]{2}T[1-4]).*", "\\1", nm_z)
398     Delta[h, tri_name] <- as.numeric(cf_z)
399 }
400
```

Código 7.13: Pasos previos necesarios para la ejecución del código.

7.7. Estimación del autoconsumo energético

```

401 ini =as.Date("2021-01-01") #donde se inicia
402 fin = as.Date("2025-05-31") #último dato disponible
403 idx = which(fecha_all >= ini & fecha_all <= fin)
404 # Se definen los nombres de las columnas de demanda horaria (h1 a h24)
405 cols_S= paste0("demhora", 1:24)
406
407 # matriz S recortada
408 S_cut= as.matrix(datos[idx, cols_S])
409
410
411 # Se calcula el autoconsumo energético horario como producto elemento a
  ↪ elemento entre la demanda observada y el efecto relativo estimado
412 Autoconsumo_E = - S_cut * A_hour
413

```

Código 7.14: Cálculo del autoconsumo energético a partir de la demanda observada y la matriz de efectos relativos estimados.

Desde este momento lo que se hace es graficar los valores obtenidos en los cálculos anteriores.

```

414
415 #El autoconsumo horario estimado
416
417 Autoconsumo_E_day = rowSums(abs(Autoconsumo_E))
418 Autoconsumo_E_day_xts= xts(Autoconsumo_E_day,order.by = fecha_p )
419 Autoconsumo_E_day_GWh =Autoconsumo_E_day_xts / 1000
420 plot(Autoconsumo_E_day_GWh,main = "Autoconsumo estimado horario en el
  ↪ sistema eléctrico peninsular",xlab = "Año",ylab = "Autoconsumo
  ↪ (GWh)",col = "darkgreen",lwd = 1)
421

```

Código 7.15: Cálculo del autoconsumo energético a partir de la demanda observada y la matriz de efectos relativos estimados.

```

422 Autoconsumo_day_MWh = rowSums(abs(Autoconsumo_E))
423
424 Autoconsumo_day_xts = xts(
425   Autoconsumo_day_MWh,order.by = fecha_p)
426
427 Autoconsumo_month_MWh = aggregate(
428   Autoconsumo_day_xts,as.yearmon,sum)
429 Autoconsumo_month_GWh = Autoconsumo_month_MWh / 1000
430 df_month = data.frame(fecha = as.Date(time(Autoconsumo_month_GWh)),
431   autoconsumo = as.numeric(Autoconsumo_month_GWh))
432 #Representación gráfica
433 ggplot(df_month, aes(x = fecha, y = autoconsumo)) +
434   geom_line(color = "darkgreen",linewidth = 1) +geom_point(color =
  ↪ "darkgreen",size = 3) + labs(title = "Autoconsumo mensual estimado en
  ↪ el sistema eléctrico peninsular",x = "Año",y = "Autoconsumo (GWh)") +
435   theme_minimal(base_size = 13)
436

```

Código 7.16: Agregación del autoconsumo energético estimado a escala mensual y representación gráfica en GWh.

```

436 # Agregación del autoconsumo diario a escala trimestral (en MWh)
437 Autoconsumo_trim_MWh= aggregate(Autoconsumo_day_xts,as.yearqtr,sum)
438
439 # Pasar a GWh
440 Autoconsumo_trim_GWh= Autoconsumo_trim_MWh / 1000
441
442 # Construcción de un data.frame con fechas y autoconsumo trimestral
443 df_trim= data.frame(fecha = as.Date(time(Autoconsumo_trim_GWh)),autoconsumo
↳ = as.numeric(Autoconsumo_trim_GWh))
444
445 #Representación gráfica
446 ggplot(df_trim, aes(x = fecha, y = autoconsumo)) +
447 geom_col(fill = "darkgreen",color = "black",width = 70) +labs(title =
↳ "Autoconsumo trimestral estimado en el sistema eléctrico peninsular",x =
↳ "Año",y = "Autoconsumo (GWh)") +
448 theme_minimal(base_size = 13)
449

```

Código 7.17: Agregación trimestral del autoconsumo energético estimado y representación mediante gráfico de barras.

```

450 Demanda_day_MWh= rowSums(datos[idx_2021, cols_dem])
451
452 Demanda_day_xts= xts(Demanda_day_MWh,order.by = fecha_p)
453 Demanda_month_GWh= aggregate(Demanda_day_xts,as.yearmon,sum) / 1000
454 Porc_autoconsumo= 100 * (Autoconsumo_month_GWh / Demanda_month_GWh)
455 df_pct= data.frame(fecha = as.Date(time(Porc_autoconsumo)),porcentaje =
↳ as.numeric(Porc_autoconsumo))
456 #Representación gráfica
457 ggplot(df_pct, aes(x = fecha, y = porcentaje)) +
458 geom_area(fill = "darkgreen",alpha = 0.35) +
459 geom_line(color = "darkgreen",linewidth = 1) +
460 labs(title = "% de autoconsumo mensual respecto al total de la demanda",x =
↳ "Mes",y = "Porcentaje (%)") +
461 theme_minimal(base_size = 13)
462

```

Código 7.18: Porcentaje mensual de autoconsumo estimado respecto a la demanda eléctrica total.

ANEXOS

H. Bibliografía

Referencias

- [1] Red Eléctrica de España. *La electricidad y el sistema eléctrico*. Consultado en 2025. 2024. URL: <https://www.ree.es/es/que-es-el-sistema-electrico>.
- [2] International Energy Agency. *Electricity*. Consulta: 2024. 2024. URL: <https://www.iea.org/energy-system/electricity>.
- [3] Financial Times Editorial Board. *The Iberian blackout is a wake-up call*. Consulta: 2025. 2025. URL: <https://www.ft.com/content/49df0517-707e-4fdd-a5ac-dea2feae8d2d>.
- [4] Red Eléctrica de España. *Estructura y funcionamiento del sistema eléctrico*. Consultado en 2025. 2024. URL: <https://www.ree.es/es/sistema-electrico/funcionamiento-del-sistema-electrico>.
- [5] Red Eléctrica de España. *La producción renovable crece en España un 10,3 % y alcanza mayores registros*. Consulta: 2025. 2025. URL: <https://www.ree.es/es/sala-de-prensa/actualidad/nota-de-prensa/2025/03/la-produccion-renovable-crece-en-Espana-un-10-3-por-ciento-2024-alcanza-mayores-registros>.
- [6] Red Eléctrica de España. *Quiénes somos*. Accedido el 26 de noviembre de 2025. 2025. URL: <https://www.ree.es/es/conocenos/quienes-somos>.
- [7] Red Eléctrica de España. *Transporte de energía eléctrica*. Accedido el 26 de noviembre de 2025. 2025. URL: <https://www.ree.es/es/transporte-electricidad>.
- [8] CNMC. *Guía del mercado eléctrico: comercialización, tarifas y agentes*. Consultado en 2025. 2025. URL: <https://www.cnmc.es>.
- [9] AleaSoft Energy Forecasting. *Demanda de electricidad y PIB en España*. Gráfico elaborado por AleaSoft con datos de REE e INE. Consultado en 2025. 2021. URL: <https://aleasoft.com/es/eficiencia-energetica-record-demanda-electricidad-2007/>.
- [10] EDP Energía. *Radiografía del autoconsumo en 2023: crecimiento y previsiones*. Consultado en 2025. 2024. URL: <https://edpenergia.es/es/blog/energia-fotovoltaica/radiografia-autoconsumo-2023-crecimiento-2024/>.
- [11] George E. P. Box, Gwilym M. Jenkins, Gregory C. Reinsel y Greta M. Ljung. *Time Series Analysis: Forecasting and Control*. 5th. Hoboken, NJ: Wiley, 2016.
- [12] Acutec. *La COVID-19 provocó la caída de un 11 % en el consumo de la luz en 2020*. Consultado en 2025. 2021. URL: <https://acutec.es/la-covid-provoco-la-caida-de-un-11-en-el-consumo-de-la-luz-en-2020/>.

- [13] Rob J. Hyndman y George Athanasopoulos. *Forecasting: Principles and Practice*. Consultado en 2025. OTexts, 2018. URL: <https://otexts.com/fpp3/>.
- [14] Hirotugu Akaike. «A new look at the statistical model identification». En: *IEEE Transactions on Automatic Control* 19.6 (1974), págs. 716-723.
- [15] Rob J. Hyndman y George Athanasopoulos. *Forecasting: Principles and Practice*. 3rd. OTexts, 2021.
- [16] Diego Peña. *Análisis de series temporales*. Alianza Editorial, 2005.
- [17] George E. P. Box, Gwilym M. Jenkins, Gregory C. Reinsel y Greta M. Ljung. *Time Series Analysis: Forecasting and Control*. Wiley, 2015.
- [18] Jeffrey M. Wooldridge. *Introductory Econometrics: A Modern Approach*. 6.^a ed. Cengage Learning, 2016.
- [19] Newtral. *Autoconsumo en España: evolución y objetivos de la Agenda 2030*. Consultado en 2025. 2023. URL: <https://www.newtral.es/autoconsumo-espana-agenda-2030/20230110/>.
- [20] C de Comunicación. *El autoconsumo fotovoltaico creció más de un 100 % en 2022*. Consultado en 2025. 2022. URL: <https://material-electrico.cdecomunicacion.es/fotovoltaica-autoconsumo/130911/autoconsumo-fotovoltaico-crecio-mas-cien-por-cien>.
- [21] María Jesús Sánchez Naranjo. *Apuntes de la asignatura Series Temporales Univariantes*. Material docente no publicado. Universidad Politécnica de Madrid. 2022.
- [22] Juan Ruiz, Jesús. *Apuntes de procesos ARMA: funciones ACF y PACF*. Diapositivas de clase. Asignatura Matemáticas Industriales. Material docente no publicado. 2024.

I. Algoritmo para la creación de modelos ARIMA

Más allá de la base matemática que puede haber detrás de la creación de un modelo ARIMA, que escapa al alcance de este Trabajo de Fin de Grado, y que ya se considera suficientemente profundizado con las fórmulas y desarrollos realizados en los primeros apartados en los que se detalló el modelo base; se pretende ahora explicar la serie de pasos que se llevaron a cabo para la elección del mismo.

I.1. Pasos para ARIMA(p,d,q)

Teniendo ya una serie temporal de nuestro interés, es decir, que represente la demanda horaria.

Ahora el siguiente paso es buscar una serie que sea estacionaria en media y varianza, se realizan los siguientes pasos, extraído de los apuntes de la asignatura Series Temporales Univariantes de María Jesús Sánchez Naranjo [21]:




Figura I.1: Diagrama de decisión para la comprobación de estacionariedad y preprocesado de series temporales previo al modelado ARIMA.

Al tener ya la serie estacionaria (en media y varianza), el siguiente paso es estimar los parámetros del modelo, para ello lo que se hace es fijarse en las funciones de autocorrelación simple y de autocorrelación parcial, ACF y PACF respectivamente.

Para ello existe también un algoritmo definido por el cual viendo las gráficas de dichas funciones se obtienen diferentes combinaciones de parámetros, como se resume en los apuntes de Jesús Juan Ruiz [22], se puede realizar de la siguiente forma:

Acf y Pacf de procesos ARMA

	Acf $\rho(h)$	Pacf $\phi_{h,h}$
AR(p)	Coeficientes no nulos que decrecen con el retardo	Los primeros p coeficientes son no nulos. $\phi_{h,h} = 0, h > p$
MA(q)	Los primeros q coeficientes son no nulos. $\rho(h) = 0, h > q$	Coeficientes no nulos que decrecen con el retardo
ARMA(p, q)	Coeficientes no nulos que decrecen con el retardo	Coeficientes no nulos que decrecen con el retardo

Figura I.2: Comportamiento teórico de las funciones ACF y PACF en procesos AR, MA y ARMA.

Nótese que, para la identificación de los parámetros estacionales (P,D,Q), el proceso es similar al no estacional, aunque en este caso la inspección de la ACF y la PACF se efectúa en los retardos asociados a la estacionalidad.

I.2. Selección del modelo

Una vez obtenido el modelo ARIMA, se puede analizar si es mejor o peor que otros mismo modelos obtenidos con estos algoritmos, para ello se pueden tener en cuenta diferentes indicadores

- Contraste en los parámetros para que verificar que los diferentes pvalores de los diferentes parámetros son menores que un valor α .
- La no dependencia ni autocorrelación de los residuos.
- Distribución normal de los residuos.
- Homocedasticidad de los residuos, es decir, varianza constante de los mismo a lo largo del tiempo.

Estos indicadores e hipótesis se pueden analizar de forma muy sencilla a través de comandos como *summary* y *checkresiduals*.